

评测维度 副本

目的	本次评测主要围绕以下三个方面展开：生成质量（Quality）、生成异常（Anomaly）率和稳定性（Stability）、生成效率（Efficiency）、生成成本（Cost）
日期	0629-0705
评测模型	HappyHorse 1.1、Seedance 2.0、Kling 3.0、Google Veo 3.1、SkyReels V4
测评结果	综合结果显示，各模型在不同维度均具有一定优势，不存在绝对意义上的"全能模型"。其中： - Seedance 2.0综合评分最高，画面质量表现最优； - Google Veo 3.1在生成速度、成本控制方面优势明显，综合能力最均衡； - Kling 3.0整体表现稳定，在质量与稳定性之间取得较好的平衡； - HappyHorse 1.1生成质量较好，但效率和稳定性相对一般； - SkyReels V4整体表现相对落后，在复杂场景下质量、稳定性及成本均存在一定提升空间。 因此，不同模型更适用于不同业务场景，应根据实际需求进行合理选择。
评测数据表	📄 AI视频生成模型评测_双盲标注数据表.xlsx 📄 模型质量评分明细表 V1.0 📄 模型质量评分明细表 V1.1 📄 AI视频生成模型评测_二值判断结果.xlsx 📄 模型客观评价数据汇总

一、评测背景

随着生成式AI技术的发展，音视频一体化生成模型不断迭代，不同模型在Prompt理解能力、画面质量、人物一致性、音频生成及整体表现等方面存在明显差异。

为了客观评价各模型生成能力，建立统一、标准化的评测体系，对不同模型进行横向比较，为模型优化、产品选型及能力分析提供依据。

二、评测概述

本次评测旨在建立统一的 AI 音视频生成模型评测体系，对模型的生成质量、生成效率及生成成本进行综合评价。

评测主要围绕以下三个方面展开：

- 质量评测（Quality Evaluation）**：重点评估模型对 Prompt 的理解与执行能力，以及生成内容在画面质量、声音品质、叙事表现、音视频同步和创意表达等方面的综合表现。

- **效率评测（Efficiency Evaluation）**：重点评估模型完成视频生成任务所需时间、任务响应速度及生成稳定性。
- **成本评测（Cost Evaluation）**：重点评估模型完成相同生成任务所需的费用、积分消耗及单位生成成本，并结合生成效果分析模型整体性价比。

通过统一 Prompt 数据集和标准化评测流程，对各模型进行横向比较，为模型优化、产品选型及实际业务应用提供客观的数据支持。

三、评测模型

 怎么来的？为什么不选择Chatgpt?

模型	版本
HappyHorse	1.1
Seedance	2.0
Kling（可灵）	3.0
Google Veo	3.1
天工 SkyReels	V4

所有模型采用：

- 视频长度：低难度：5s；中难度：10s，高难度：10s；
- 视频尺寸16:9；
- 画质：720P。

保证公平测试。

四、评测方案

1. 评测数据集构造

为提升评测结果的代表性和稳定性，本次评测**采用分层构建方式**，根据 Prompt 的复杂程度划分为**简单、中等、困难**三个等级，并按照 **1:2:1** 的比例进行数据分布。构建 100 条 **Prompt**。

其中：

- **简单 Prompt（25%）**：主要验证模型的基础生成能力及 Prompt 遵循能力。
- **中等 Prompt（50%）**：覆盖实际业务中的主流生成场景，是本次评测的核心组成部分。
- **困难 Prompt（25%）**：重点考察模型在复杂场景、多主体、多动作、长文本理解及综合生成能力方面的表现。

通过上述难度分布，可在保证测试覆盖率的同时，更全面地评估模型在不同复杂度任务下的生成效果、稳定性及泛化能力。

数据集详情见 [《AI 视频模型 Benchmark Prompt 数据集 V1.0》](#)

2. 测评方式

2.1 1/2/3/4/5评分

本次评测采用统一 Prompt 输入、统一生成参数和统一评测标准，对各模型生成的音视频结果进行标准化评估。评测采用 **5 分制评分（1~5 分）**，分数越高表示模型生成效果越优。

评测内容主要包括以下三个方面：

- **生成质量（Quality）**：评估模型在 Prompt 遵循、画面质量、叙事流畅度、声音品质、音视频同步、音频表现力及创意与美感等方面的综合表现。
- **生成效率（Efficiency）**：评估模型完成生成任务所需时间、响应速度及生成稳定性。
- **生成成本（Cost）**：评估模型完成相同生成任务所需的费用、积分消耗及综合性价比。

评测结束后，将结合各维度评分计算模型综合得分，并输出各模型的能力分析、优势与不足、典型案例及适用场景，为模型选型、能力优化及业务应用提供客观依据。

对比维度



音视频遵循+画面质量+叙事流畅度+声音品质+音视频同步+音频呈现力+创意与美感

- 音视频遵循：遵循Prompt内容，确保人物、音效、内容依照文本要求执行；
- 画面质量：画面清晰锐利，色彩层次丰富，细节饱满，无瑕疵；
- 叙事流程度：镜头衔接自然，节奏精准，故事完整有逻辑；
- 声音品质：声音在人声清晰度、收音、音效等维度呈现出的综合优劣水平；
- 音视频同步：音频信号与视频画面在播放时保持完全一致的时间对应关系，无延迟或错位；
- 音频呈现力：音频通过人声表现、音效表现等元素传递内容、烘托氛围的能力
- 创意与美感：镜富有创意，光影运用出色，艺术风格鲜明。

音视频遵循	画面质量	叙事流程 度	声音品质	音视频同步	音频呈现力	创意与美感
Prompt与画面内容遵循： 核心主体、场景或动作缺失 数量、属性、位置关系错误 景别、角度或运镜未执行	画面模糊/不清晰 文字/字幕错误 关键信息缺失	镜头衔接生硬 情节跳跃/断裂 信息表达不连贯	人声清晰度/口齿 人声杂音/底噪 人声发音不清	多/少口型 口型与台词不一致 延迟/不同步	说话机械感重 语气生硬/语调单一 情绪表达不足	创意平庸/缺乏新意 画面无艺术感 风格不够统一
主体与时序连续遵循：	色彩层次差 光影效果差	人物动作突兀	人声卡顿	错口型	口音/唱歌表现差	人物造型缺乏创意

人物或物体身份、外观发生变化	主体不清/模糊	场景切换不自然	收音不稳定	画面人物不发声	情感投入不足	构图平淡无亮点
动作中断、顺序错误或交互不完整		逻辑关系不合理	音质失真/破音	口型与情绪不匹配	表演不自然	视觉冲击力不足
场景、空间、因果前后不一致						
人声与台词内容遵循： 台词漏说、错说或擅自改写 说话人数、角色或声源不符 语种、方言、口音或情绪不符	细节饱满度不 纹理/材质粗糙 边缘锯齿明显	信息密度不足 节奏拖沓/冗长 推进节奏不合理	音效卡顿 音效失真 收音忽大忽小	单人说话响应多人多人声位混乱 声音来源不匹配	情绪表现不足 氛围烘托不足 音效层次感差	缺乏情感共鸣 故事张力不足 代入感不强
环境音、音效与音乐遵循： 环境音、动作音效或背景音乐缺失 音效类型、方向、远近或强弱不符 音乐风格、节奏或氛围不匹配	色彩失真/偏色 光影不自然 特效粗糙/假感重	时间线混乱 叙事重点不突出 前后呼应性差	杂音/噪音 环境噪音过大 底响明显	音效节奏不自然 背景音乐不匹配 氛围营造不足	音效节奏不自然 背景音乐不匹配 氛围营造不足	风格定位不明显 艺术风格不统一 视觉创意不足
声画联动与文字信息遵循： 有画面无声音或有声音无对应画面 动作、口型与音效触发关系错误 字幕、文字或标识缺失、错误	关键物体缺失 构图单调无层次 运动模糊异常	故事未完整呈现 结尾仓促/虎头蛇尾 因果关系不清晰	音量异常 音量忽大忽小 动态范围不足	多/少音效 环境音与画面不符 动作音效缺失	整体氛围感不足 声音层次混乱 听感不舒适	画面缺乏创意点 光影运用单调 艺术感染力低

细分检查：

子项	占比
Prompt与画面内容遵循	30%
主体与时序连续遵循	20%
人声与台词内容遵循	20%

人声与台词内容遵循	20%	主要问题 Major	某个明确要求缺失或错误，已经影响内容完整度、信息传达或观看体验
环境音、音效与音乐遵循	15%		
声画联动与文字信息遵循	15%		
		致命问题 Critical	核心主体、关键动作、主要台词、事件逻辑或声画严重错误，导致Prompt意图无法成立

(2) 画面质量 (20)

标注重点主要检查：

- 清晰度与对焦；
- 细节与纹理；
- 曝光、色彩和光影；
- 人物、物体是否存在变形；
- 是否闪烁、抖动、模糊；
- 是否有穿模、重影、边缘粘连；
- 画面前后质量是否稳定。

分数	评价	备注
5	优秀 (Excellent)	画面整体清晰、对焦准确，主体轮廓、面部、手部、服装、商品材质及背景细节均能稳定辨认； 曝光正常，亮部不过曝、暗部不过度丢失，色彩自然协调，无明显偏色或帧间色彩跳变； 人物、物体结构完整，比例合理，无明显变形、穿模、重影、边缘粘连、纹理漂移； 镜头运动过程中画质稳定，无明显闪烁、卡顿、拖影、焦点漂移或分辨率突变。 允许存在仅在暂停放大后才能发现、且不影响观看的极轻微瑕疵。
4	良好 (Good)	画面整体清晰稳定，主体和关键细节可正常辨认。 允许出现1~2处轻微问题，如局部纹理不够细腻、背景略微模糊、短暂轻度闪烁、边缘轻微粘连、光影或色彩存在小幅波动，但问题不集中在主体面部、手部、关键商品或核心动作区域，不影响正常观看及业务使用。
3	一般 (Fair)	画面基本可观看，主体和主要内容能够辨认，但存在较明显的质量问题。 例如局部持续模糊、细节缺失、人物手部或物体边缘轻度变形、色彩或亮度不稳定、短时闪烁、运动拖影、背景纹理漂移。 问题已经影响画面精致度和真实感，但没有造成主体无法识别或视频无法理解。
2	较差 (Poor)	画面存在多处明显质量缺陷，如主体持续模糊、人物五官或肢体明显异常、物体结构变化、严重过曝或欠曝、频繁闪烁、边缘粘连、重影、拖影、明显穿模。 关键主体或关键动作受到影响，需要反复观看才能辨认，难以达到正常业务使用标准。

1	失败（Fail）	画面严重损坏或基本不可用。 主体无法辨认，人物或物体大面积崩坏，出现持续黑屏、花屏、严重乱码、严重闪烁、结构完全错误、分辨率极低或大部分画面模糊；核心内容因画质问题无法判断，不具备正常观看和评测价值。
---	----------	---

5分精简版备注：

画面清晰、对焦准确，主体、面部、手部、商品材质及背景细节稳定；曝光、色彩、光影自然，无明显变形、穿模、重影、闪烁、拖影、焦点漂移或画质突变。仅允许不影响观看的极轻微局部瑕疵。

(3) 叙事流畅度（20）

标注重点主要检查：

- 故事或事件是否完整；
- 开始、发展、结果是否清楚；
- 动作顺序是否合理；
- 镜头切换是否自然；
- 信息是否前后连贯；
- 节奏是否过快或拖沓；
- 是否存在跳跃、重复、断裂。

分数	评价	备注
5	优秀 (Excellent)	视频叙事目标明确，事件具有清楚的开始、发展和结果； 人物行为、动作顺序、空间变化及因果关系自然成立，前后信息一致； 镜头之间衔接顺畅，场景切换、景别变化和重点信息呈现均有明确目的； 节奏张弛合理，无明显拖沓、重复、突然跳跃或信息缺口。 即使没有文字说明，观看者也能准确理解人物在做什么、事件如何发展以及最终结果。
4	良好 (Good)	主要故事和事件顺序完整，人物行为与因果关系基本合理，镜头衔接总体自然。 允许存在1~2处轻微节奏问题，如个别镜头稍长、转场略生硬、次要动作交代不足或局部信息重复，但不会导致理解中断，也不影响主要叙事目标。
3	一般 (Fair)	视频的基本主题和主要事件可以理解，但叙事存在明显不够顺畅的问题。 例如部分动作被省略、镜头切换突兀、事件过渡不足、节奏忽快忽慢、重点不够突出、结尾较仓促。 观看者能够理解大意，但需要自行补充部分过程或因果关系。
2	较差 (Poor)	叙事仅保留部分有效信息，动作、镜头或事件之间缺乏清晰连接；

		出现明显时间线混乱、前后状态冲突、关键步骤缺失、场景突然切换、情节重复或无意义停留。 观看者难以理解事件为何发生、人物行为目的或最终结果。
1	失败（Fail）	视频内容严重碎片化或逻辑混乱，镜头、动作和事件之间基本没有可理解的关系； 故事未形成，前后内容相互冲突，关键主体或行为突然出现、消失或改变。 观看者无法判断视频表达的主题和事件过程，不具备完整叙事价值。

5分精简备注

叙事目标明确，事件具有完整的开始、发展和结果；动作顺序、空间变化和因果关系自然成立，前后信息一致；镜头衔接和场景转换顺畅，节奏合理，无拖沓、重复、突跳或关键过程缺失，观看者无需额外解释即可理解完整内容。

(4) 声音品质（15）

标注重点，主要检查声音本身的技术质量：

- 人声是否清楚；
- 是否有底噪、杂音；
- 是否有爆音、破音、削波；
- 是否卡顿、断裂；
- 音量是否忽大忽小；
- 发音是否自然；
- 音色是否稳定；
- 是否出现电子感、机械感。

注意：不要在本项判断“声音和画面是否同步”，同步问题放在“音视频同步”。

分数	评价	备注
5	优秀 (Excellent)	人声、环境音、动作音效及音乐均清晰自然，主体声音易于辨认； 无明显底噪、杂音、爆音、削波、破音、卡顿、断裂或异常回声； 音量稳定，动态范围合理，声音不过小、不过载，远近层次自然； 人物发音清楚，音色前后一致，无明显电子感、机械感、吞音或异常拉长。 不同声音同时出现时仍能保持清晰，不相互严重遮盖。
4	良好（Good）	声音整体清楚、自然、稳定，主要人声和关键音效能够准确辨认。 允许存在轻微底噪、局部音量波动、短暂轻度失真、个别发音不够清楚或混音略显拥挤，但不影响主要内容理解，也不会造成明显听觉不适。
3	一般（Fair）	主要声音可以听清，但存在明显技术问题。

		例如持续轻度底噪、人声略闷或刺耳、个别词语发音模糊、音量忽大忽小、短暂卡顿、音效质感失真或音乐遮挡部分人声。 整体仍可理解，但听感和专业度明显不足。
2	较差（Poor）	声音存在频繁或严重问题，如人声大量含混、音色明显机械、持续噪声、爆音、破音、明显削波、声音断裂或音量严重不稳定； 人声、音乐和音效相互遮挡，导致部分关键信息无法听清，已经明显影响理解和使用。
1	失败（Fail）	声音基本不可用，包括无声、主体声音完全无法辨认、持续严重噪声或失真、大面积断音、音频文件损坏，或大部分台词因技术质量问题无法听清。 无法满足基本听觉和信息传递要求。

5分精简备注：

人声、环境音、动作音效和音乐清晰自然，音量稳定、层次合理；无明显底噪、杂音、爆音、破音、卡顿、断裂或异常回声；发音清楚、音色稳定，无机械感，多个声音同时出现时仍可清晰辨认。

(5) 音视频同步 (5)

标注重点主要检查：

- 口型和台词是否同步；
- 动作和音效是否同时发生；
- 声音来源是否对应正确人物或物体；
- 声音方向和画面位置是否一致；
- 镜头切换后声音是否正确变化；
- 是否出现持续提前或延迟；
- 音视频是否逐渐漂移。

分数	评价	备注
5	优秀 (Excellent)	人物口型、嘴部开合和台词发声高度一致，发声开始、停顿和结束时间准确； 脚步、碰撞、开门、倒水、敲击等动作音效与画面事件同步触发； 声音正确对应发声人物、动物或物体，无声源错配； 左右方向、远近和空间位置与画面一致； 镜头切换、场景变化和动作节奏发生变化时，声音也同步调整。 全片无明显提前、延迟或持续漂移。
4	良好（Good）	主要台词、动作和音效同步准确，声源对象及空间位置基本正确。 允许出现极短暂、轻微的口型或音效偏差，通常只在仔细观察或逐帧查看时可发现，不影响观看者对事件的判断，不形成持续性的提前、延迟或漂移。

3	一般（Fair）	整体声画关系基本成立，但存在多处可察觉的轻度不同步。 例如部分台词口型偏快或偏慢、动作音效稍早或稍晚、个别声音来源不明确、场景切换后声音延迟变化。 问题影响自然度，但不会导致声音对象或主要事件被误解。
2	较差（Poor）	存在明显且频繁的声画错位，如主要人物说话与口型明显不一致、关键动作发生后较长时间才出现音效、声音对应错误人物或物体、声音方向与画面位置相反，或音视频随着播放逐步漂移。 已经明显影响观看和事件理解。
1	失败（Fail）	声音与画面基本无对应关系，台词与人物口型完全不符，关键音效随机出现或对应错误事件，声源对象严重错配，或音视频整体持续大幅提前、延迟。观看者无法判断谁在说话、什么动作产生了声音，声画联动失效。

5分精简备注：

口型与台词发声准确一致，动作音效与画面事件同步触发；声音正确对应人物或物体，方向、远近和空间位置与画面一致；场景、镜头和动作变化时声音同步变化，全片无明显提前、延迟或持续漂移。

(6) 音频呈现力 (5)

标注重点，这一项不是看“声音清不清楚”，而是看声音是否具有表达力：

- 语气是否自然；
- 情绪是否充分；
- 重音、停顿、语速是否合理；
- 音乐、音效、人声层次是否清楚；
- 是否能营造氛围；
- 是否具有感染力；
- 声音是否服务叙事。

分数	评价	备注
5	优秀（Excellent）	人声语气、语速、停顿、重音、音高和情绪变化自然，能够准确表达人物身份、态度和场景情绪； 对白、旁白、音乐、环境音和动作音效层次清晰，主次关系合理，不互相抢占； 音乐与音效能够强化动作、转场、节奏和叙事重点，环境声音有效建立空间和氛围； 整体声音具有感染力、节奏感和沉浸感，既不过度表演，也不机械平淡。
4	良好（Good）	人声表达自然，情绪和语气基本符合内容； 音乐、音效和环境音能够支持画面氛围，声音层次较清楚。允许存在局部语气稍平、个别重音或停顿不够准确、部分音效表现不足等轻微问题，但整体仍具备较好的情绪传递和听觉体验。

3	一般（Fair）	声音能够完成基本信息表达，但表现力一般。 人物语气较平、情绪变化不足，语速或停顿略显机械； 音乐、环境音和动作音效虽然存在，但主次关系不清楚，或未能有效强化情节。 整体可以理解，但感染力、层次感和氛围塑造不足。
2	较差（Poor）	人声表达明显机械、生硬或情绪错误，语速、停顿和重音不自然； 音乐、音效与内容情绪不匹配，或多个声音层次混乱、相互干扰； 缺乏必要的氛围铺垫和事件强调，使视频情绪表达失真或观看体验明显下降。
1	失败（Fail）	声音完全缺乏有效表达，人物语气、情绪与内容严重冲突，或全片声音机械单调、层次混乱； 音乐和音效对内容产生明显误导，无法建立基本氛围和叙事重点。 声音不仅没有增强视频，反而严重破坏内容理解和情绪表达。

5分精简备注：

人声语气、语速、停顿、重音和情绪自然准确；对白、音乐、环境音和动作音效层次清晰、主次合理；声音能够强化动作、转场和叙事重点，有效营造空间与氛围，整体具有感染力、节奏感和沉浸感。

(7) 创意与美感 (5)

标注重点主要检查：

- 构图是否有设计；
- 色彩和光影是否协调；
- 风格是否统一；
- 镜头与声音设计是否有表达意图；
- 是否只是普通生成，还是有创意呈现；
- 是否符合商业场景；
- 是否存在明显模板感、同质化；
- 创意是否服务内容，而非无意义炫技。

分数	评价	备注
5	优秀 (Excellent)	视频具有明确且统一的视觉与听觉创意概念； 构图、景别、色彩、光影、材质、场景、运镜和声音设计相互协调，能够形成完整风格； 画面层次、视觉重点和节奏安排合理，关键镜头具有记忆点； 创意表达与主题、产品或故事高度相关，不是无意义堆砌特效；

		在同类生成结果中具有一定差异化和辨识度，同时兼顾审美完成度、信息传达和业务可用性。
4	良好（Good）	整体风格统一，构图、色彩、光影及声音氛围协调，具有一定设计感和审美完成度。 存在部分有创意的镜头、转场或视听表达，但差异化和记忆点略弱，或局部设计较常见。 整体仍明显优于普通模板化生成结果。
3	一般（Fair）	画面和声音整体基本协调，构图、配色和风格没有明显错误，但创意较普通，表现方式常规或模板化； 部分镜头缺乏视觉重点，风格统一性一般，艺术表达和记忆点不足。 能够正常使用，但难以形成明显辨识度。
2	较差（Poor）	画面缺乏明确设计，构图失衡、配色不协调、光影混乱或风格前后变化明显； 镜头、特效、音乐和音效存在无目的堆砌，创意与主题关系较弱；整体审美完成度低，视觉重点不清楚，难以满足常规商业展示要求。
1	失败（Fail）	视频缺乏基本审美和统一风格，构图、色彩、光影、材质及声音设计严重混乱； 创意表达与主题无关或产生明显误导，画面无视觉重点，整体呈现粗糙、杂乱、不协调。 没有可识别的艺术或商业表达价值。

5分精简备注

具有明确统一的视听创意概念，构图、景别、色彩、光影、材质、运镜和声音设计协调；画面层次和视觉重点清楚，关键镜头有记忆点；创意服务主题而非堆砌特效，在同类结果中具有差异化、辨识度和较高业务完成度。

标注人员统一操作方法

为了避免标注人员一次观看就凭感觉打分，建议每条视频至少观看三遍。

操作轮次	操作要求
第一次观看	正常速度、不中断，判断整体主题、叙事、视听体验
第二次观看	重点看画面，检查清晰度、主体、动作、镜头、构图和生成瑕疵
第三次观看	重点听声音，检查人声、音效、音乐、情绪和声画同步
必要时复看	对疑似变形、错位、卡顿位置暂停或降低播放速度
最终提交	先判断是否存在严重问题，再填写各维度分数和问题理由

统一评分边界

标注人员可以先判断问题严重程度，再确定分数.

问题级别	说明	通常对应分数
极轻微问题	需暂停或放大才发现，不影响体验	5分
轻微问题	正常观看可以发现，但不影响理解和使用	4分
明显问题	影响完整度、自然度或专业度，但仍能理解	3分
严重问题	明显影响主题、事件理解或业务使用	2分
致命问题	核心内容失效或基本不可用	1分

标注理由统一格式

每个低于5分的维度都要求填写：

问题类型 + 发生位置 + 具体表现 + 影响结果

例如：

画面质量：视频3.2秒至4.1秒人物右手出现明显结构变形，同时杯体边缘发生粘连，影响主体真实性，评为3分。
声音
创意与美感：整体构图和色彩基本协调，但镜头设计较常规，缺乏视觉重点和记忆点，属于基础可用水平，评为3分。

2.2 二值判断

在完成综合评分后，对生成结果进行二值检查，用于判断视频是否存在严重质量问题。二值判断采用是（Yes）/否（No） 的方式进行记录，不参与评分，但作为模型质量统计的重要依据。

检查项	是否存在	备注
视频连续性异常	☐ 是 / ☐ 否	卡顿、跳帧、闪烁、动作不连贯等
现实合理性异常	☐ 是 / ☐ 否	穿模、漂浮、肢体异常、物理规律错误等

3. 盲标评测

本次评测采用盲标（Blind Evaluation） 方式进行。

为保证评测结果的公平性和客观性，所有模型生成结果均进行匿名化处理，隐藏模型名称、版本信息及其他可能影响评测判断的标识。评测人员仅依据生成结果本身进行评分，不参考模型来源及历史表现。

同时，所有测试样本均采用**随机顺序展示**，避免因展示顺序或模型品牌造成主观偏差，确保各模型在统一标准下完成评测。



4. 客观指标统计

除主观质量评分外，本次评测同步统计模型生成过程中的客观指标，用于辅助分析模型在实际应用中的效率及成本表现。客观指标不参与质量评分，仅用于模型综合能力对比。

指标	描述	单位
生成耗时	从提交生成任务到视频生成完成所消耗的总时间。	秒（s）
生成成本	完成一次视频生成任务所消耗的费用或平台积分。	元（¥） / Credits

统计说明：

- 生成耗时以平台实际完成时间为准；
- 生成成本以平台实际扣费或积分消耗为准；
- 所有模型均采用相同 Prompt、相同生成配置进行统计，确保结果具有可比性；
- 客观指标仅用于效率与成本分析，不计入质量评分。

五、评测结果



综合本次评测结果，

- Google Veo 3.1**在生成质量、稳定性、生成效率等方面表现最为均衡，是最适合作为**通用生产环境默认模型**的选择；
- Seedance 2.0**凭借最高的综合质量评分和较低的 API 成本，更适合**高质量商业广告及大规模视频生成**；
- Kling 3.0**在稳定性方面表现突出，适用于**长镜头和连续动作场景**；
- HappyHorse 1.1**可满足基础视频生成需求，但复杂场景表现一般；
- SkyReels V4**目前更适合功能验证或实验性应用，不建议作为正式商业项目的首选模型。

1. 整体评测指标

1.1 1/2/3/4/5 评分法

为客观衡量各模型在不同难度场景下的视频生成能力，本次评测采用**加权综合评分法（Weighted Scoring Method）**。

所有模型在**低难度、中难度、高难度**三个场景下完成相同数量的测试任务，每个任务均由评测人员依据统一评分标准进行盲评，最终计算各难度平均得分，并汇总形成模型最终成绩。

最终得分采用100分制。

（一）评分流程

（1）按照难度等级划分测试集

- 低难度
- 中难度
- 高难度

2.每个模型完成全部测试任务。

3. 每个生成结果采用统一评分标准进行评估。

（二）测评维度

采用 1/2/3/4/5 五分制。每个维度先打 1-5 分，再按权重折算成 100 分。

- 音视频遵循（30）+画面质量（20）+叙事流畅度（20）+声音品质（15）+音视频同步（5）+音频呈现力（5）+创意与美感（5）= 100

$$\text{综合得分} = \sum_{i=1}^n \left(\frac{\text{维度评分}}{5} \times \text{维度权重} \right)$$

注意：维度评分：1~5 分；维度权重：各维度对应权重；综合得分：100 分制。

然后，各难度得分采用对应测试集所有样本的平均值：

$$Score_{difficulty} = \frac{\sum_{i=1}^N Score_i}{N}$$

其中：

- N 为该难度测试样本数量
- Score 为单条视频最终评分

得到：

- 低难度得分
- 中难度得分
- 高难度得分

(三) 综合评分计算

为保证综合评分能够真实反映模型在不同复杂度场景下的整体表现，本次评测依据测试集中各难度提示词的数量占比进行加权统计。测试集按照**低难度：中难度：高难度 = 1:2:1**进行构建，因此综合评分采用相同权重进行计算，即低难度占25%、中难度占50%、高难度占25%。最终综合得分计算公式如下：

计算方式为：

$$\text{Final Score} = 0.25 \times S_{Low} + 0.50 \times S_{Medium} + 0.25 \times S_{High}$$

这样更能体现模型在复杂场景下的能力。

(四) 评分等级

为了方便阅读，可以增加等级划分。

综合得分	等级	说明
≥95	S	行业领先，生成效果优秀，稳定性极高
90-94.9	A	整体表现优秀，可满足大多数生产需求
85-89.9	B	效果良好，复杂场景存在一定优化空间
80-84.9	C	基本可用，复杂场景表现一般
<80	D	生成质量较弱，稳定性有待提升

(五) 模型质量评测分值

模型	HappyHorse 1.1(A)			Seedance 2.0(S)			Kling 3.0(B)			Google Veo 3.1(A)			SkyReel	
分类统计	低难度	中难度	高难度	低难度	中难度	高难度	低难度	中难度	高难度	低难度	中难度	高难度	低难度	中难度
总分	94.8	90.8	88	95.4	96.6	93.4	87.4	89.2	85	94.2	95.9	87.2	78.4	71
综合评分	91.10			95.50			87.7			93.3			71	

1.2 二值判断异常率和稳定率测评结果



总结：从二值判断统计结果来看，

Seedance 2.0 和 **Kling 3.0** 在**稳定性**方面表现较为突出，**异常率**整体较低；

Google Veo 3.1 在**视频连续性**方面具有一定优势，但现实合理性仍存在优化空间；

HappyHorse 1.1a 两轮测试结果波动较大，建议进一步扩大样本量验证模型表现；

SkyReels V4 在两轮测试中异常率均相对较高，尤其是在复杂场景下，稳定性和现实合理性仍有较大的提升空间。

为进一步评估各模型生成结果的稳定性，在完成综合评分后，对所有生成视频进行了二值判断统计。二值判断主要针对**视频连续性异常**（如卡顿、跳帧、闪烁、动作不连贯等）和**现实合理性异常**（如穿模、漂浮、肢体异常、物理规律错误等）两个维度进行检查，并采用 **Yes（存在异常）/No（无异常）** 的方式记录。该结果不参与综合评分，仅作为模型稳定性分析的重要参考。

本次测试中，每个模型共生成 **20 条视频样本**，测试集按照**低难度：中难度：高难度 = 1:2:1** 的比例进行构建，即低难度 5 条、中难度 10 条、高难度 5 条。根据异常统计结果，分别计算视频连续性异常率、现实合理性异常率及整体稳定率。

计算公式如下：

异常率：

稳定率：

$$\text{异常率} = \frac{\text{Yes数量}}{\text{检查总次数}} \times 100\%$$

$$\text{稳定率} = \frac{\text{No数量}}{\text{检查总次数}} \times 100\% = 1 - \text{异常率}$$

$$\text{最终异常率} = \frac{\text{标注1异常数} + \text{标注2异常数}}{40} \times 100\%$$

其中：

- **Yes** 表示存在异常；
- **No** 表示未发现异常；
- **总检查次数 = 视频数量 × 检查维度数量**

结合之前评测方案，**模型稳定性统计表**，与综合评分表并列展示，例如：

模型	综合评分	视频连续性异常率	现实合理性异常率	整体稳定率
HappyHorse 1.1	91.1	17.5%	27.5%	77.5%
Seedance 2.0	95.5	10.0%	22.5%	83.75%
Kling 3.0	87.7	17.5%	10.0%	86.25%
Google Veo 3.1	93.3	12.5%	22.5%	82.5%

SkyReels V4	71.65	32.5%	37.5%	65.0%
-------------	-------	-------	-------	-------

1.3 客观评价

为全面评估各模型的实际应用能力，本次评测对模型生成音视频的耗时进行了统计分析。生成耗时指模型从任务提交至生成结果返回所消耗的时间，不包含人工输入 Prompt、结果下载及人工审核等额外时间。

测试过程中，各模型采用统一的测试 Prompt、统一参数配置及相同网络环境，每条 Prompt 独立运行一次，并分别统计低难度、中难度和高难度场景下的生成耗时，以保证测试结果具有可比性。

本次测试按照**低难度：中难度：高难度 = 1:2:1**的比例构建测试集，并分别计算各模型不同难度场景下的平均生成耗时，用于评估模型的生成效率。

（一）生成效率评测

综合平均耗时统计结果表明，
Google Veo 3.1生成效率最高，
Seedance 2.0紧随其后；
天工 SkyReels V4与Kling 3.0整体效率处于中等水平；
HappyHorse 1.1a生成耗时最长，高难度场景下效率下降较为明显。

（1）统计方法

生成耗时采用平均值统计。

计算公式：

$$\text{平均生成耗时} = \frac{\sum_{i=1}^N T_i}{N}$$

其中：

- Ti：第 i 条视频生成耗时；
- N：对应难度下测试样本数量。

综合生成耗时按照测试样本数量进行加权计算：

由于测试集采用：

低：中：高 = 1:2:1

因此：

$$\text{综合耗时} = 0.25T_{Low} + 0.50T_{Medium} + 0.25T_{High}$$

（2）效率等级

综合平均耗时	效率等级	说明
≤1分15秒	★★★★★ 优秀	行业领先，生成效果优秀，稳定性极高
1分15秒~2分钟	★★★★☆ 良好	整体表现优秀，可满足大多数生产需求

2分钟~2分30秒	★★★★☆☆ 中等	效果良好，复杂场景存在一定优化空间
2分30秒~3分钟	★★☆☆☆☆ 一般	基本可用，复杂场景表现一般
>3分钟	★☆☆☆☆ 较低	生成质量较弱，稳定性有待提升

(3) 模型测评分值

模型	低难度 平均耗时	中难度 平均耗时	高难度 平均耗时	综合平均 耗时	效率评价	效率等级
Google Veo 3.1	00:00:41	00:01:16	00:01:23	00:01:07	生成速度最快，效率表现最佳。	★★★★★ 优秀
Seedance 2.0	00:00:56	00:01:31	00:02:22	00:01:36	生成效率较高，耗时表现优秀。	★★★★☆ 良好
天工SkyReels V4(天工AI)	00:01:13	00:02:04	00:03:51	00:02:23	生成效率中等偏高，整体表现稳定。	★★★☆☆ 中等
Kling 3.0/可灵	00:02:19	00:02:22	00:02:31	00:02:24	生成效率中等，耗时较为稳定。	★★★☆☆ 中等
HappyHorse 1.1a	00:01:47	00:03:53	00:04:03	00:03:14	生成耗时最长，生成效率较低。	★☆☆☆☆ 较低

(4) 生成效率分析

本次评测对各模型在低、中、高难度提示词下的生成耗时进行了统计，并以综合平均耗时作为生成效率评价依据。

从整体结果来看，**Google Veo 3.1**以**1分07秒**的综合平均耗时位居第一，在各难度场景下均保持较快的生成速度，生成效率表现最佳。

Seedance 2.0综合平均耗时**1分36秒**，整体生成效率较高，在速度与稳定性方面表现较为均衡。

天工 SkyReels V4与**Kling 3.0**综合平均耗时分别为**2分23秒**和**2分24秒**，两者耗时接近，在不同难度场景下生成速度较为稳定，但整体效率略低于前两者，属于中等水平。

HappyHorse 1.1a综合平均耗时为**3分14秒**，尤其在中、高难度提示词下生成时间增长较为明显，整体生成效率相对较低。

总体来看，各模型随着提示词复杂度的提升，生成耗时均呈现不同程度的增加。

(二) 生成成本评测



从**成本角度**来看，Seedance 2.0具有最明显的经济优势；如果结合你前面评测中的**质量、稳定性、生成效率**综合考虑，则Google Veo 3.1虽然成本较高，但整体综合性能最均衡，更适合作为高质量视频生产的首选模型；对于预算有限、需要大量生成内容的场景，Seedance 2.0和HappyHorse 1.1则具有更高的成本效益。

(1) 统计方法

生成成本采用**平均单次生成成本**进行统计。

计算公式：

$$\text{平均生成成本} = \frac{\sum_{i=1}^N C_i}{N}$$

由于测试集比例为

低：中：高 = 1:2:1

因此：

其中：

- Ci：第 i 条测试样本消耗的积分（或费用）
- N：对应难度测试样本数量

综合生成成本计算方式：

$$\text{综合生成成本} = 0.25C_{Low} + 0.50C_{Medium} + 0.25C_{High}$$

(2) 效率等级

综合平均成本	成本等级	说明
≤20	★★★★★ 极低	生成成本最低，成本控制表现最佳。
21~50	★★★★☆ 较低	生成成本较低，成本优势较明显。
51~80	★★★☆☆ 中等	生成成本适中，成本表现较为均衡。
81~120	★★☆☆☆ 较高	生成成本较高，整体成本投入较大。
>120	★☆☆☆☆ 很高	生成成本较高，整体成本投入较大。

(3) 模型测评成本

模型	API价格(\$/分钟)	换算积分	建议积分	成本等级
Seedance 2.0	9.07	4.91	5	★★★★★ 极低
HappyHorse 1.1	9.9	5.36	5	★★★★☆ 较低
Kling 3.0 1080P(Pro)	20.16	10.92	11	★★★☆☆ 中等
SkyReels V4	21	11.38	11	★★☆☆☆ 较高

Google Veo 3.1	24	13	13	★★☆☆☆ 较高
----------------	----	----	----	----------

(4) 生成成本分析

本次评测依据各模型官方 API 单价，按照统一的计费标准换算为生成积分，对模型在相同生成任务下的成本进行统计分析。

从整体结果来看，Seedance 2.0的生成成本最低，API价格为**9.07 美元/分钟**，折算约**4.91 积分**，建议按**5积分**计费，成本等级为★★★★★（极低），在所有参评模型中具有最明显的成本优势，适用于大规模、批量化的视频生成任务。

HappyHorse 1.1API价格为**9.90 美元/分钟**，折算约**5.36 积分**，建议按**5积分**计费，整体成本略高于 Seedance 2.0，但仍保持较低的资源消耗，在兼顾生成质量与成本控制方面具有一定优势。

Kling 3.0（1080P Pro）API价格为**20.16 美元/分钟**，折算约**10.92 积分**，建议按**11积分**计费，成本处于中等水平，适合对画质有一定要求，同时能够接受中等成本投入的应用场景。

SkyReels V4API价格为**21 美元/分钟**，折算约**11.38 积分**，建议按**11积分**计费，与 Kling 3.0成本接近，但略高于 Kling，整体属于较高成本模型。

Google Veo 3.1API价格最高，为**24 美元/分钟**，折算约**13积分**，建议按**13积分**计费，成本等级为★★☆☆☆（较高）。虽然单次生成成本最高，但结合前文评测结果，其在生成质量、生成效率及稳定性方面均表现突出，因此更适合对视频质量要求较高的商业级应用。

(5) 综合分析

综合成本统计结果可以看出，各模型可大致分为三个成本梯队：

成本梯队	模型	特点
低成本	Seedance 2.0、HappyHorse 1.1	成本投入低，适合批量生成、预算敏感型项
中等成本	Kling 3.0（1080P Pro）、SkyReels V4	成本适中，适用于画质与成本兼顾的业务场
高成本	Google Veo 3.1	单次生成成本最高，但综合能力突出，适合作。

六、评测维度拆解与问题归因体系（Evaluation Taxonomy & Error Attribution）

本章节用于将前述 7 项一级评测维度进一步拆解为可执行、可统计、可归因的二级指标与三级缺陷标签，并结合本轮 4 张汇总表形成结果归因框架。

目的不是增加主观评分项，而是解决三个问题：**为什么扣分、问题发生在哪里、后续应该由哪类能力优化。**

1. 数据口径与归因边界

本轮结果表覆盖以下 4 类信息：

- 1. 按难度汇总：低/中/高难度 Prompt 下的模型总分；

- 2. 按场景汇总：影视剧情、商业广告、建筑漫游、游戏打斗、演唱会现场；
- 3. 二值异常统计：视频连续性异常、现实合理性异常；
- 4. 客观统计：生成耗时、积分/生成成本。

从当前表格可以直接得到模型的**总体表现、场景表现、难度退化、连续性/现实性异常率、耗时和成本**。

需要特别说明：

- 当前汇总表没有逐条记录“手部变形、口型错位、漏音效、镜头指令遗漏”等三级缺陷的出现次数，因此本章节不会反向虚构三级缺陷频次；
- 下文“已观测结论”只使用表格能够直接支持的数据；
- 下文“建议重点排查/候选根因”属于基于现有结果的**归因方向**，后续需通过逐样本 Error Tag 统计验证；
- 二值判断表中的模型名存在 HappyHorse 1.1a，其他表中为 HappyHorse 1.1，正式报告发布前建议统一版本命名口径。

2. 一级—二级—三级评测指标树

A. 音视频遵循 / Instruction & Multimodal Fidelity (30%)

二级指标	建议占比	三级检查点	典型问题标签
A1 Prompt视觉语义遵循	9%	主体、数量、属性、场景、位置关系	FID-ENTITY-MISS 主体缺失；FID-COUNT 数量错误；FID-RELATION 关系错误
A2 动作与镜头指令遵循	6%	动作执行、动作顺序、景别、视角、运镜	FID-ACTION 动作错误；FID-ORDER 顺序错误；FID-CAMERA 镜头错误
A3 主体与时序连续遵循	6%	身份、外观、服装、物体形态、时序状态	FID-ID-DRIFT 身份漂移；FID-STATE-DRIFT 状态漂移；FID-TIME 时序错误
A4 人声与台词遵循	5%	台词内容、说话角色、人数、语言/方言、情绪	FID-DIALOG-MISS 漏台词；FID-DIALOG-WRONG 错台词；FID-LANG 语言/口音不符
A5 环境音/音效/音乐及文字遵循	4%	环境音、动作音效、BGM、字幕/文字/标识	FID-SFX-MISS 音效缺失；FID-MUSIC 音乐不符；FID-TEXT 字幕/文字/标识不对应

判定重点： 本维度只回答“模型有没有按 Prompt 做”，不评价“做得是否漂亮”“声音是否清晰”。

B. 画面质量 / Visual Quality (20%)

二级指标	建议占比	三级检查点	典型问题标签
B1 清晰度与对焦	4%	主体清晰、焦点稳定、运动中可辨认	VIS-BLUR 模糊；VIS-FOCUS 焦点漂移；VIS-RES 分辨率/锐度不足
B2 人体与物体结构	4%	五官、手部、肢体、物体几何结构	VIS-ANATOMY 人体异常；VIS-GEOMETRY 物体结构错误；VIS-STRUCTURE 结构失真
B3 纹理与材质	3%	皮肤、服装、商品、建筑、表面材质	VIS-TEXTURE 纹理漂移；VIS-MATERIAL 材质失真；VIS-DETAIL 细节丢失
B4 曝光、色彩与光影	3%	亮暗关系、偏色、光源方向、帧间稳定	VIS-EXPOSURE 曝光异常；VIS-COLOR 偏色；VIS-LIGHT 光影错误
B5 时域画质稳定	4%	闪烁、重影、拖影、抖动、局部突变	VIS-FLICKER 闪烁；VIS-GHOST 重影；VIS-MOTION-BLUR JITTER 抖动
B6 特效与合成完成度	2%	粒子、流体、烟雾、爆炸、特效融合	VIS-VFX 特效粗糙；VIS-COMPOSITE 合成穿帮

判定重点： 本维度评价画面“技术成片质量”，不重复扣 Prompt 没执行的问题。

C. 叙事流畅度 / Narrative Coherence (20%)

二级指标	建议占比	三级检查点	典型问题标签
C1 事件完整性	5%	开始—发展—结果是否完整	NAR-INCOMPLETE 事件不完整；NAR-END 结尾仓促
C2 因果与逻辑	4%	行为动机、事件因果、状态前后一致	NAR-CAUSAL 因果断裂；NAR-CONFLICT 前后冲突
C3 动作连续性	4%	动作是否被截断、跳步、重复	NAR-ACTION-JUMP 动作跳跃；NAR-REPEAT 重复
C4 镜头与场景衔接	4%	转场、景别变化、空间转换	NAR-CUT 转场突兀；NAR-SPACE 空间跳变
C5 节奏与信息密度	3%	节奏拖沓/过快、重点是否突出	NAR-PACING 节奏异常；NAR-DENSITY 信息密度不合理

判定重点： Prompt 本身可以被执行，但如果事件组织方式仍让观看者难以理解，则归入叙事流畅度。

D. 声音品质 / Audio Technical Quality (15%)

二级指标	建议占比	三级检查点	典型问题标签
D1 人声可懂度	4%	发音、吐字、吞音、清晰度	AUD-INTELLIGIBILITY 人声含混；AUD-PRON 发音异常
D2 噪声与纯净度	3%	底噪、杂音、异常回声	AUD-NOISE 噪声；AUD-ECHO 回声
D3 失真与连续性	3%	爆音、破音、削波、卡顿、断裂	AUD-CLIP 削波/爆音；AUD-DISTORT 失真；AUD-DROP 断音
D4 音量与动态	3%	音量稳定、动态范围、声音遮挡	AUD-LEVEL 音量波动；AUD-MASK 人声被音乐/音效遮挡
D5 音色稳定性	2%	音色前后一致、机械感、电子感	AUD-TIMBRE 音色漂移；AUD-ROBOTIC 机械感

判定重点： 只评价音频本身的技术质量，不在此维度评价声画同步。

E. 音视频同步 / Audio-Visual Synchronization (5%)

二级指标	建议占比	三级检查点	典型问题标签
E1 口型同步	1.50%	发声开始/结束、嘴型与音节	SYNC-LIP 口型错位
E2 动作—音效同步	1.00%	脚步、碰撞、开门、倒水、技能等	SYNC-SFX 动作音效提前/延迟
E3 声源对象匹配	1.00%	谁在说话、哪一物体发声	SYNC-SOURCE 声源错配
E4 空间定位	0.75%	左右、远近、方位、镜头移动	SYNC-SPATIAL 空间声场错误
E5 全局时间漂移	0.75%	持续提前、延迟、逐渐漂移	SYNC-DRIFT 音视频漂移

F. 音频呈现力 / Audio Expressiveness (5%)

二级指标	建议占比	三级检查点	典型问题标签
F1 语气与韵律	1.25%	语速、停顿、重音、音高	EXP-PROSODY 韵律机械
F2 情绪表达	1.25%	情绪强度、人物身份、场景情绪	EXP-EMOTION 情绪不足/错误
F3 声音层次	1.00%	人声、音乐、环境音、音效主次	EXP-LAYER 层次混乱
F4 氛围塑造	0.75%	空间感、沉浸感、环境建立	EXP-ATMOS 氛围不足
F5 叙事服务性	0.75%	是否强化动作、转场和重点	EXP-NARRATIVE 声音未服务叙事

G. 创意与美感 / Creativity & Aesthetics (5%)

二级指标	建议占比	三级检查点	典型问题标签
G1 构图与视觉重点	1.00%	主体关系、画面层次、视觉焦点	ART-COMP 构图平淡/失衡
G2 色彩与光影设计	1.00%	色彩策略、气氛光、视觉统一	ART-COLOR 配色普通/冲突；ART-LIGHT 光影缺失设计
G3 风格一致性	1.00%	镜头、场景、材质、声音风格统一	ART-STYLE 风格漂移
G4 创意与记忆点	1.00%	非模板化、差异化、关键镜头	ART-NOVELTY 模板感；ART-MEMORY 缺乏记忆点
G5 商业/业务完成度	1.00%	主题服务、信息表达、可交付性	ART-USABILITY 业务可用性不足

3. 二值异常进一步拆解

当前二值判断只有“视频连续性异常”和“现实合理性异常”。为了让异常可以直接进入 BadCase 库，建议进一步拆成以下标签。

3.1 视频连续性异常（CONTINUITY）

三级标签	定义	典型表现
CON-FRAME-SKIP	跳帧/时间跳跃	动作突然跨阶段、关键帧缺失
CON-STUTTER	卡顿/重复帧	画面短暂停住或动作反复
CON-FLICKER	帧间闪烁	人物、纹理、亮度连续闪变
CON-MOTION-BREAK	动作连续性断裂	手势、走路、转身过程中断
CON-ID-DRIFT	主体身份漂移	人脸、服装、物体造型前后改变
CON-SCENE-DRIFT	场景连续性漂移	背景结构、空间关系突然变化

3.2 现实合理性异常（REALISM）

三级标签	定义	典型表现
REA-ANATOMY	人体结构异常	多指、少指、肢体错位、五官崩坏
REA-PENETRATION	穿模/碰撞错误	手穿杯子、人物穿墙、物体互相穿透
REA-FLOAT	漂浮/接触关系错误	人、物体无支撑悬浮
REA-PHYSICS	物理规律错误	水流、重力、惯性、碰撞不符合常识
REA-SCALE	尺度比例异常	人物与场景/物体尺寸关系不合理
REA-MATERIAL	材质行为错误	液体像固体、布料/玻璃反应异常

4. 问题归因原则：一个问题“主归因一次”，必要时记录关联影响

为了避免同一个问题在多个维度重复扣分，需要采用 **Primary Cause（主归因）+ Impact（影响维度）** 的方式记录。

现象	主归因维度	可记录关联影响	不应重罚
Prompt要求“人物说A”，实际说成B	A 人声与台词遵循	E口型同步、F表达力（若同时异常）	D声音品质
台词内容正确，但口型晚约0.5s	E 音视频同步	观看体验	A遵循作为额外扣分
人声内容正确但爆音严重	D 声音品质	F呈现力	A遵循
手部从5指变7指	B 人体/物体结构	现实合理性二值=是	A遵循
人物走到一半瞬间换衣服	A3主体与时序连续 / CON-ID-DRIFT	C叙事连贯	B画面质量
镜头没有执行“360°环绕”	A2动作与镜头指令遵循	G创意完成度	C叙事
动作合理，但剪辑突然跳到另一场景	C镜头与场景衔接	连续性二值（达到异常阈值时）	A遵循
水流方向明显违背重力	REA-PHYSICS + B视觉结构/特效	现实合理性二值=是	C叙事

归因优先级

发生多维问题时，建议按以下顺序判断：

Prompt要求是否被执行 → 主体/时序是否稳定 → 现实/结构是否成立 → 叙事是否成立 → 声画是否同步 → 单独画质/音质 → 表现力与审美。

这样可以减少“因为一个核心错误导致所有维度一起低分”的重复惩罚。

七、基于本轮4张结果表的问题归因总结

1. 本轮综合质量结果

以下总分为两位标注员汇总结果的均值：

模型	综合质量均分	当前结果定位
Seedance 2.0	95.53	本轮综合质量第一，整体稳定
Google Veo 3.1	94	综合质量第二，商业/演唱会场景突出
HappyHorse 1.1	89.73	基础质量较好，高难度存在明显退化
Kling（可灵）3.0	88.68	整体中上，现实合理性异常率最低
天工 SkyReels V4	73.15	本轮综合质量明显落后，连续性/现实性需优先排查

该排序反映本轮测试集和当前生成参数下的结果，不等价于模型在所有场景中的绝对能力排名。

2. 难度退化分析：复杂 Prompt 鲁棒性

模型	低难度	中难度	高难度	高-低变化	归因判断
HappyHorse 1.1	96.9	89.15	83.7	-13.2	复杂约束增加后明显退化，建议重点排查多主体、多动作、镜头同时出现时的遵循与时序稳定
Seedance 2.0	96.9	95.75	93.7	-3.2	本轮复杂度鲁棒性最好，复杂 Prompt 下仍维持高分
Kling（可灵）3.0	86.3	90.6	87.2	0.9	结果未呈单调退化，说明“难度”不是唯一解释变量；需经缺陷标签分析
Google Veo 3.1	95.2	95.25	89.3	-5.9	高难度出现一定退化，但总体仍处于较高水平
天工 SkyReels V4	82.2	71.05	69.4	-12.8	基础能力已偏弱，复杂任务进一步放大问题，属于结构性弱

归因结论

高难度 Prompt 中通常同时包含：

- 多主体；
- 多阶段动作；
- 多种运镜；
- 多声源；
- 空间音频；
- 口型/动作/音效精准同步；
- 长约束链。

因此高难度退化不能简单归因为“画质下降”，优先应从以下能力链排查：

复杂指令解析 → 多约束保持 → 时序/身份一致性 → 多事件并行生成 → 多声源同步 → 长时段稳定性。

3. 场景能力矩阵

两位标注员按场景汇总均值如下：

场景	HappyHorse	Seedance	Kling	Veo	SkyReels
影视剧情	93.63	95.75	87	88.88	69.63
商业广告	91.13	91.13	88.38	98.13	71.25
建筑漫游	91.25	97.25	88.38	90.88	75.13
游戏打斗	88.75	98.63	92.13	95.63	85.38
演唱会现场	83.88	94.88	87.5	96.5	64.38

场景归因观察

影视剧情

主要压力点：

- 台词内容；
- 口型；
- 多人物交互；
- 前后身份一致；
- 第一视角/主观镜头；
- 人声与环境音共存。

建议核心 Error Tag： FID-DIALOG-★、 SYNC-LIP、 FID-ID-DRIFT、 NAR-ACTION-JUMP。

商业广告

主要压力点：

- 商品/手部细节；
- 流体、喷雾、材质；
- 微距与高速摄影；
- 节奏化音效；
- 商业审美与视觉完成度。

建议核心 Error Tag： VIS-ANATOMY、 VIS-MATERIAL、 VIS-VFX、 SYNC-SFX、 ART-COMP、 ART-USABILITY。

建筑漫游

主要压力点：

- 建筑结构稳定；
- 环绕/推进运镜；
- 大空间几何一致性；
- 环境声远近/方位变化；
- 空间音频。

建议核心 Error Tag： VIS-GEOMETRY、 CON-SCENE-DRIFT、 SYNC-SPATIAL、 FID-CAMERA。

游戏打斗

主要压力点：

- 高速运动；
- 多主体交互；
- 特效、爆炸、粒子；
- 技能顺序；

- 镜头快速变化；
- 动作与音效逐事件同步。

建议核心 Error Tag： CON-MOTION-BREAK 、 VIS-VFX 、 FID-ORDER 、 SYNC-SFX 、 NAR-ACTION-JUMP 。

演唱会现场

主要压力点：

- 大规模人群；
- 主唱/乐队/舞团多主体；
- 口型和演奏动作；
- 音乐节拍；
- 灯光/烟花/舞台特效；
- 现场空间混响与镜头位置联动。

建议核心 Error Tag： SYNC-LIP 、 SYNC-SFX 、 FID-SPEAKER 、 EXP-LAYER 、 SYNC-SPATIAL 、 CON-ID-DRIFT 。

4. 二值异常：结构性 BadCase 归因

4.1 视频连续性异常率

模型	两位标注员平均异常率	风险等级
Seedance 2.0	10%	低
Google Veo 3.1	13%	低
HappyHorse 1.1a	18%	中
Kling 3.0/可灵	18%	中
天工 SkyReels V4	33%	高

重点归因标签：

CON-FRAME-SKIP 、 CON-STUTTER 、 CON-FLICKER 、 CON-MOTION-BREAK 、 CON-ID-DRIFT 、 CON-SCENE-DRIFT 。

4.2 现实合理性异常率

模型	两位标注员平均异常率	风险等级
Kling 3.0/可灵	10%	低
Seedance 2.0	23%	中
Google Veo 3.1	23%	中
HappyHorse 1.1a	28%	中偏高
天工 SkyReels V4	38%	高

重点归因标签：

REA-ANATOMY、REA-PENETRATION、REA-FLOAT、REA-PHYSICS、REA-SCALE、REA-MATERIAL。

4.3 二值结果解读

- Seedance：连续性异常率最低，说明本轮时域稳定性表现较好；但现实合理性仍有 23%，后续不能只看总分，需要单独建立物理/人体 BadCase 库。
- Veo：连续性异常较低，现实合理性异常处于中间水平。
- Kling：现实合理性异常率最低，是本轮较明确的相对优势；但整体总分并非最高，说明“现实合理”不能代替 Prompt 遵循、视听完成度等其他能力。
- HappyHorse：连续性和现实合理性均存在一定风险，高难度退化较明显。
- SkyReels：连续性和现实合理性两项异常率均为本轮最高，应优先判断为时空一致性/物理合理性类结构性问题，而不是只归结为审美或单点画质问题。

5. 客观指标：效率与成本归因

模型	综合平均生成耗时	平均积分/成本	结果观察
Google Veo 3.1	1分07秒	13	本轮耗时最短、积分最低，同时质量排名第二
Seedance 2.0	1分36秒	117	质量第一，但积分消耗最高档
天工 SkyReels V4	2分23秒	117	成本高且综合质量较低，当前性价比不占优
Kling（可灵）3.0	2分24秒	64	时间中等偏慢，成本居中
HappyHorse 1.1	3分14秒	45	本轮平均耗时最长，成本中等

5.1 客观指标不应混入质量扣分

建议将模型最终报告拆成两个 Scorecard：

Quality Scorecard（质量）

Prompt遵循、画面、叙事、声音、同步、表现力、创意。

Serving Scorecard（服务效率）

生成耗时、失败率、重试率、排队时间、单位成本、单位有效样本成本。

这样可以避免出现“画质高但贵”和“生成快但质量低”被一个总分掩盖的问题。

八、模型级问题归因摘要（Model Capability Profiling）

本节中的“候选根因”仅表示下一轮应优先检查的能力方向，不代表当前汇总表已经证明某个三级缺陷发生次数最多。

模型	已观测优势	已观测风险	建
Seedance 2.0	综合质量最高；高难度保持93.70；连续性异常10%最低；游戏/建筑场景突出	现实合理性异常23%；积分117较高	继否
Google Veo 3.1	综合94.00；商业98.13、演唱会96.50；耗时1:07、积分13	高难度降至89.30；现实合理性异常23%	复体
HappyHorse 1.1	低难度96.90；影视/商业/建筑基础表现较好	高难度83.70；现实异常28%；平均耗时3:14；演唱会83.88	复生
Kling（可灵）3.0	现实合理性异常10%最低；游戏场景92.13	综合88.68；连续性异常18%；各难度结果非单调	建审
天工 SkyReels V4	游戏场景相对自身最好（85.38）	综合73.15；连续性33%；现实性38%；演唱会64.38；成本117	时为

九、标注一致性与仲裁规则（建议新增）

本轮两位标注员的样本总分存在明显分歧。按 20 条样本计算，两位标注员之间的平均绝对分差约为：

模型	两位标注员平均绝对分差	最大单样本分差
Google Veo 3.1	4.1	15
Seedance 2.0	5.15	17
Kling（可灵）3.0	7.35	34
HappyHorse 1.1	8.15	52
天工 SkyReels V4	13.25	50

其中部分样本出现 30～52 分的大分差。该现象首先应被视为**标注一致性风险**，不能直接解释成模型波动。

1. 建议仲裁触发条件

满足任一条件，样本自动进入争议池：

- 两位标注员**总分差** ≥ 10 分；
- 任一一级维度评分差 ≥ 2 档；
- 一人判断 Critical，另一人判断 Minor/无问题；
- 二值判断“连续性异常/现实合理性异常”结果不一致；
- 两人主问题标签属于完全不同的根因族，例如一人判 `FID-*`，另一人判 `VIS-*`。

2. 仲裁输出要求

仲裁人必须补充：

- 最终一级维度分数；
- Primary Error Tag；
- Secondary Error Tag（可空）；
- 问题时间段；
- 严重等级；
- 仲裁理由；
- 是否进入 BadCase 库。

十、BadCase 问题归因标准

1. 严重等级

等级	名称	判定标准	对业务影响
S0	Pass	无明显问题或仅暂停放大可见	可直接使用
S1	Minor	正常观看可见，但不影响语义和主要体验	可使用，非优先修复
S2	Major	明显影响自然度、完整度或专业度	建议修复/重生成
S3	Critical	核心主体、事件、台词、声画关系或物理逻辑失效	不可使用，必须进入BadCase

2. BadCase唯一主标签原则

每条 BadCase 至少记录一个、最多记录三个标签：

- `primary_error`：唯一主问题；
- `secondary_error_1`：可选；
- `secondary_error_2`：可选。

禁止将“画面不好”“声音不自然”“不符合预期”作为最终标签，必须落到可操作的三级标签。

十一、建议新增的逐样本标注字段

为了让下一轮汇总表能够真正做到“问题归因”，建议在原评分表中增加以下字段：

字段	类型	示例
sample_id	String	ADV_HIGH_003
model_id	String	Seedance_2.0
scene	Enum	商业广告
difficulty	Enum	高
dimension	Enum	E_音视频同步
primary_error	Enum	SYNC-SFX
secondary_error	Enum	REA-PHYSICS
severity	Enum	S2_Major
start_time	Float	3.2
end_time	Float	4.1
evidence	Text	开瓶动作结束约0.4s后才出现音效
binary_continuity	Bool	FALSE
binary_realism	Bool	FALSE
annotator_id	String	A02
arbitration_status	Enum	pending/pass/arbitrated
final_score	Number	86

十二、后续统计指标建议

在现有“平均分”之外，大厂评测报告建议至少增加以下指标：

1. 质量类

- Overall Quality Score;
- Dimension Score;
- Scene Score;
- Difficulty Score;
- Critical Error Rate;
- Major+Critical Error Rate;
- Prompt Pass Rate;
- Continuity Failure Rate;
- Realism Failure Rate;

- Lip-sync Failure Rate;
- Audio Event Missing Rate。

2. 鲁棒性类

- **Difficulty Degradation**: 高难度相对低难度的分数下降;
- **Scene Variance**: 不同场景间的能力波动;
- **Worst-Case Score**: 最弱场景/最弱难度分数;
- **Long Constraint Robustness**: 长 Prompt、多约束任务通过率。

3. 标注质量类

- 双人评分平均绝对分差;
 - 二值判断一致率;
 - 一级维度一致率;
 - Error Tag 一致率;
 - 仲裁率;
 - 仲裁后改判率。
-

十三、最终归因结论

基于当前 4 张汇总表，本轮模型差异不能只用一个“综合分”解释，至少应拆成四条能力链：

1. 内容生成能力链

Prompt理解 → 主体/动作/镜头执行 → 叙事完整 → 创意完成度

2. 时空稳定能力链

主体一致 → 动作连续 → 场景连续 → 现实/物理合理

3. 音视频生成能力链

台词生成 → 音频技术质量 → 音频表现力 → 口型/动作音效/空间声场同步

4. 工程服务能力链

生成成功 → 等待耗时 → 重试稳定 → 单次成本 → 单位有效样本成本


本轮结果显示：

- **Seedance 2.0** 的核心优势是综合质量和复杂任务稳定性;
- **Google Veo 3.1** 在保持高质量的同时，本轮效率和积分成本最有优势;

- **Kling（可灵）3.0** 的现实合理性异常率最低，但仍需要三级 Error Tag 才能解释总分未进入第一梯队的原因；
- **HappyHorse 1.1** 的主要风险集中在高难度退化、部分复杂场景和生成耗时；
- **天工 SkyReels V4** 的连续性与现实合理性异常均较突出，应优先建设时域一致性和物理合理性 BadCase 集，而不是首先优化审美项。

因此，下一轮评测的核心升级方向不是继续增加更多一级评分维度，而是把现有维度“标签化、可归因化、可统计化”。

最终形成：



十四、核心结论

1. 综合分析

本次评测从**生成质量、视频稳定性、生成效率、生成成本**四个维度，对 HappyHorse 1.1、Seedance 2.0、Kling 3.0、Google Veo 3.1 和 SkyReels V4 五款模型进行了综合评测。

整体来看，不同模型在不同评测维度表现存在明显差异，没有单一模型能够在所有指标上均保持绝对领先，而是在**画质、稳定性、效率及成本**之间形成了不同侧重。

其中：

- **Seedance 2.0**综合评分最高，画面质量表现最佳；
- **Google Veo 3.1**综合能力最均衡，在生成效率方面优势明显；
- **Kling 3.0**整体稳定性最佳，现实合理性表现突出；
- **HappyHorse 1.1**具有一定成本优势，但复杂场景下稳定性有所下降；
- **SkyReels V4**在复杂 Prompt 下生成质量和稳定性均存在一定不足。

因此，在实际业务中，应结合具体应用场景选择最适合的模型，而不是单纯依据某一项指标进行选择。

3. 各模型优缺点分析

模型	优点	缺点	推荐指数
Google Veo 3.1	综合能力均衡； 生成速度最快； 画质优秀； 复杂 Prompt 表现稳定	API 成本较高	★★★★★
Seedance 2.0	综合评分最高；	现实合理性仍有少量异常	★★★★★

	商业广告画质优秀； Prompt 遵循性较好； API 成本最低		
Kling 3.0/可灵	稳定率最高；现实合理性最佳； 长镜头表现稳定	生成效率一般； 画面表现略逊于前两者	★★★★☆
HappyHorse 1.1	综合评分较高； 成本较低； 简单场景表现良好	高难度 Prompt 耗时增长明显； 复杂场景稳定性不足	★★★★☆☆
天工SkyReels V4(天工 AI)	可完成基础视频生成； 中低难度任务可用	综合评分最低； 稳定性不足； Prompt 遵循性较弱； 复杂场景异常较多	★★☆☆☆

4. 不同业务场景推荐模型

应用场景	推荐模型	推荐理由
AI数字人	Google Veo 3.1	口型、动作、镜头衔接自然，生成速度快
商业广告	Seedance 2.0	产品质感突出，光影表现优秀，画面细节最佳
电商宣传	Seedance 2.0 / Google Veo 3.1	商品展示完整，广告表现力较强
企业宣传片	Google Veo 3.1	综合质量高，效率优势明显
演唱会、大型活动	Google Veo 3.1 / Seedance 2.0	多主体及复杂特效处理能力较强
长镜头拍摄	Kling 3.0	视频连续性和现实合理性表现稳定
批量视频生产	Seedance 2.0	API 成本最低，适合预算敏感项目
日常内容创作	HappyHorse 1.1	成本较低，可满足简单视频需求
模型验证、原型测试	SkyReels V4	可完成基础功能验证，但不建议直接用于正式生产

5. 不同 Prompt 难度下模型表现

低难度 Prompt	低难度场景主要包含人物问候、简单产品展示、基础镜头运动等内容，对模型综合能力要求较低。 评测结果显示：	适用于： AI数字人
------------	--	--

推荐模型 ★★★★★ ★ Google Veo 3.1 ★★★★★ ★ Seedance 2.0	各模型均能够完成基础生成任务，画面质量差异相对较小。 其中： - Google Veo 3.1生成速度最快； - Seedance 2.0画面细节表现最好； - HappyHorse 1.1成本较低； - Kling 3.0整体表现稳定； - SkyReels V4能够完成基础任务，但画面细节略逊。	- 简单宣传视频 - 企业介绍 - 产品介绍
中难度 Prompt 推荐模型 ★★★★★ ★ Seedance 2.0 ★★★★★ ★ Google Veo 3.1	中难度 Prompt 开始加入复杂动作、多主体交互、产品广告等内容，对模型理解能力提出更高要求。 例如： - 商业广告 - 产品展示 - 人物交互 评测发现： Google Veo 与 Seedance 对 Prompt 理解较准确，商业画面完整。 Kling 能够完成主要内容，但镜头表现相对保守。 HappyHorse 商业美学略显不足。 SkyReels 出现额外对白、Prompt 遵循性不足等问题。	适用于： - 品牌广告 - 电商视频 - 产品宣传片
高难度 Prompt 推荐模型 ★★★★★ ★ Google Veo 3.1 ★★★★★ ★ Seedance 2.0 ★★★★★ Kling 3.0	高难度 Prompt 包括： - 大型演唱会 - 多人物互动 - 长镜头 - 舞台灯光 - 烟花特效 - 复杂空间运动 此类场景能够充分体现模型综合能力。 评测结果表明： Seedance 与 Google Veo 均能够保持较高画面质量。 Kling 在镜头连续性方面表现较好。 HappyHorse 与 SkyReels 出现： - 转场逻辑错误 - 空间关系异常 - 运镜稳定性不足 说明复杂场景仍存在一定优化空间。	

6. 模型选型建议

使用需求	推荐模型
综合能力优先	★★★★★ Google Veo 3.1
画质优先	★★★★★ Seedance 2.0
稳定性优先	★★★★☆ Kling 3.0
成本优先	★★★★★ Google Veo 3.1
批量生产	★★★★★ Google Veo 3.1
高质量商业项目	★★★★★ Seedance 2.0
长视频或连续生成	★★★★☆ Kling 3.0
简单内容生成	★★★☆☆ HappyHorse 1.1
测试验证	★★☆☆☆ SkyReels V4

7. 使用注意事项

根据业务目标选择模型。 如果优先考虑生成质量，可选择 **Seedance 2.0**；如果需要兼顾质量、速度和稳定性，**Google Veo 3.1**更适合作为默认方案；对于长镜头或强调稳定性的任务，**Kling 3.0**更具优势。

Prompt 复杂度会直接影响模型表现。 随着提示词复杂度提升，各模型生成耗时均有所增加，高难度场景下更容易出现镜头衔接、空间关系、人物交互等异常，建议采用结构化 Prompt，并逐步增加约束条件。

关注 Prompt 遵循性。 在商业广告、数字人播报等场景，应重点检查是否存在模型自动添加对白、字幕或未要求元素等情况，避免影响最终交付效果。


兼顾效率与成本。 批量内容生产时，可优先考虑 **Seedance 2.0**（成本低）或 **Google Veo 3.1**（速度快）；对于预算有限的项目，可结合生成质量要求合理选择模型，避免单纯追求最低成本。

保留人工审核环节。 对商业广告、品牌宣传、影视内容等高要求场景，建议结合人工复核，对视频连续性、现实合理性、音画同步及 Prompt 遵循性进行最终确认，以保证交付质量。

十五、具体案例

1. 低难度案例

影视剧情：一名女性导购微笑说“您好，欢迎光临，有什么需要的”。

HappyHorse 1.1	Seedance 2.0	Kling（可灵）3.0	Google Veo 3.1	天工SkyReels V4(天工AI)
				

分析

本案例属于低难度提示词，人物动作较为简单，各模型均能够较好完成生成任务。

其中：

- Google Veo人物动作最自然；
- Seedance人物细节更加丰富；
- Kling整体较稳定；
- HappyHorse能够完成基本生成；
- SkyReels人物口型略有偏差。

因此，低难度场景下模型整体差异较小。

2. 中难度案例

商业广告：写实商业广告风格，一只手拧开气泡水瓶并缓缓倒入玻璃杯，气泡不断升起，瓶盖、水流、气泡与背景音乐节奏精准同步。

HappyHorse 1.1	Seedance 2.0	Kling（可灵）3.0	Google Veo 3.1	天工SkyReels V4(天工AI)
				

分析

本案例主要考察模型在**商业广告场景**下的产品展示能力、画面美学设计以及 Prompt 指令遵循能力。

从测试结果来看：

- **Seedance 2.0**与**Google Veo 3.1**均能够准确理解提示词要求，在产品构图、液体动态、光影表现及商业广告氛围方面表现较为优秀，整体生成质量较高。
- **Kling 3.0**能够较好完成产品主体生成，但镜头构图较为单一，广告表现力略显不足。
- **HappyHorse 1.1**能够完成基本生成任务，但商业美学设计及音效表现相对欠缺。
- **SkyReels V4**出现了**额外生成对白字幕**的问题，说明模型在 Prompt 遵循性方面存在一定偏差，影响了最终广告内容的准确性和专业性。

综合推荐

- 商业广告、品牌宣传片： 优先推荐 **Seedance 2.0** 和 **Google Veo 3.1**，两者在产品质感、画面美学及 Prompt 遵循性方面表现最佳。
- 产品细节展示： **Kling 3.0**可作为备选，但建议优化镜头设计。
- 基础产品展示： **HappyHorse 1.1**能够满足基本需求，但在商业表现力方面略逊一筹。
- 正式商业项目： **SkyReels V4**建议加强人工复核，重点关注模型是否生成提示词之外的内容。这样也与前面报告中关于**现实合理性异常**和**Prompt 遵循性**的评测结果保持一致。

3. 高难度案例

演唱会现场：超写实摇滚演唱会风格。超大型体育场演唱会，数万名观众共同参与，歌手、乐队、舞团和特效团队完成完整高潮演出，一镜到底结合舞台轨道、摇臂、无人机及观众席穿梭运镜，舞台升降、激光矩阵、烟花、喷火、LED巨幕、体积光和粒子特效持续联动；人物口型、乐器演奏、舞蹈动作、观众互动及所有舞台特效严格跟随音乐节拍，空间混响和现场氛围随镜头位置实时变化。

HappyHorse 1.1	Seedance 2.0	Kling（可灵）3.0	Google Veo 3.1	天工SkyReels V4(天工AI)
				

分析


从测试结果来看：

- Seedance 2.0**与**Google Veo 3.1**均未发现明显异常，在视频连续性、镜头衔接及现实合理性方面表现最佳，能够较好完成复杂演唱会场景的生成任务。
- Kling 3.0**整体表现稳定，仅在高速运镜过程中出现轻微模糊，对最终观看体验影响较小。
- HappyHorse 1.1**与**SkyReels V4**在复杂镜头切换过程中均出现画面衔接及转场逻辑问题，说明其在复杂动态场景下的时序一致性和空间建模能力仍有进一步提升空间。

综合推荐：

- 商业宣传片、演唱会、电影级复杂场景： 优先推荐 **Google Veo 3.1** 和 **Seedance 2.0**。
- 长镜头、人物连续动作场景： 推荐 **Kling 3.0**。
- 简单场景或快速验证： 可选择 **HappyHorse 1.1** 或 **SkyReels V4**。

4. 异常案例

HappyHorse 1.1	Seedance 2.0	Kling（可灵）3.0	Google Veo 3.1	天工SkyReels V4(天工AI)
				

异常类型：现实合理性异常) 人物交互异常 人物口部与液体交互不自然，液体运动轨迹存在异常。 物理规律异常 液体流动不符合真实物理规律，缺乏自然过渡。 动作逻辑异常 液体生成逻辑存在偏差，呈现从口腔内部直接喷流而出的效果。 商业真实性不足 液体表现失真，影响广告画面的真实性与产品表现力。	异常类型：现实合理性异常) 现实合理性异常 喷雾方向与喷嘴位置不一致，喷射轨迹违反真实物理规律。 物体交互异常 喷嘴与喷雾出口对应关系错误，喷射逻辑存在偏差。 产品展示异常 产品喷射效果失真，影响广告画面的真实性和产品可信度。	异常类型：现实合理性异常) Prompt循环异常 语音内容与提示词不一致，额外生成未要求的语气词。 语音自然性异常 语速偏快，停顿与节奏不符合自然表达习惯。 语音生成异常 语音输出存在冗余词汇，影响播报准确性和自然度。	异常类型：现实合理性异常) 异常描述： 开门过程中出现双门重叠，场景结构生成异常。 桌面物品无外力作用下发生异常抖动，物理表现不合理。 咖啡机启动时机与人物操作不同步，设备响应早于人物接触动作，交互逻辑错误。	异常类型：现实合理性异常) 异常描述： 模型额外生成未要求的对白内容，且瓶盖开启过程中手部与瓶盖交互存在异常，物体运动不符合真实物理规律。
---	--	--	---	--