




Dify 主播风格 LoRA训练数据集自动化搭建报告

从 BV 号输入、字幕提取、候选片段审核到训练集导出与离线评测


https://www.bilibili.com/video/BV1Ht7h6TEiJ/?spm_id_from=333.337.search-card.all.click&vd_source=531dbd8a344a07a02b9fc9efee9e35f5

项目主题	使用 Dify 搭建主播风格 LoRA 模型训练集
工作周期	本周阶段性复盘
Dify 版本	1.51.0
报告定位	项目过程、节点设计、问题修复、实施效果与后续规划

报告摘要

本周围绕“如何使用 Dify 自动化构建主播风格 LoRA 训练数据集”完成了从方案设计、 workflow 搭建、节点提示词设计、Python 清洗代码、质量审核、批次去重到离线评测网站的完整闭环。项目核心不是让模型重新仿写主播，而是以公开视频字幕为事实来源，最大限度保护主播原话、口语节奏、反问、类比、真实案例和情绪表达，再将其整理为可用于微调的 system/user/assistant 数据。

本周形成的主链路：



1. 项目规则

本项目的目标是把目标主播的公开视频内容转换为高质量 LoRA 训练样本，使模型学习主播的表达方式，而不是记忆或复制具体内容。训练数据必须满足以下规则：

- 来源真实：assistant 回答必须能够在原字幕片段中找到依据，不允许凭空补写观点、总结或事实。
- 单一话题：每条样本只解决一个明确问题，话题切换时必须拆分。
- 问题匹配：用户问题应由回答内容反推，具备真实背景、困惑和情绪，不得只把标题改成问句。
- 片段完整：回答要有明确观点和足够上下文，不能只保留残句、口头禅或依赖前文的内容。
- 风格明显：优先保留反问、重复强调、类比、案例、调侃、现实建议、情绪递进和直播互动感。
- 最小清理：只处理时间戳、SRT 序号、明显错别字、断句和无意义重复，禁止改写主播原意。
- 风险剔除：删除广告招生、隐私、过时临时事实、无边界绝对化表达、错误字幕和上下文残留。
- 可训练格式：最终统一输出 messages 数组，并保留 video_id、anchor_name、topic、style_tags、answer_source 等 metadata。

2. 项目角色与模块职责分工

相关方	主要职责	输入	输出/验收
项目负责人	定义训练目标、审核规则与最终准入线	主播、视频范围、训练目标	可训练数据集与评测结论
Dify 工作流	串联字幕、LLM、代码、迭代和聚合节点	BV 数组或单个 BV	结构化候选片段与训练样本
字幕/视频来源	提供公开视频字幕或音视频	BV号、字幕、音频	可追溯原始素材
大模型节点	分段、提取、生成问题、评分和审核	清洗后的字幕与规则提示词	严格 JSON 结果
Python 代码节点	清洗、解析、去重、格式化与统计	模型输出字符串/数组	稳定对象、数组、计数与错误信息
人工审核者	抽检来源忠实度、风格与风险	候选样本、原字幕	通过/拒绝与原因
离线评测网站	批量展示、对比、打分和导出	dataset_json、字幕或音视频	表格、报告、CSV/Excel/JSONL

3. PE 可行性评估

PE 在本报告中指通过 Prompt Engineering 与工作流编排，将原本依赖人工逐条整理的任务拆成可复用、可校验的自动化节点。综合本周试跑结果，方案具备较高可行性，但必须采用“模型生成 + 代码约束 + 规则审核 + 人工抽检”的组合，而不能依赖单一大模型一次完成。


评估项	结论	说明
技术可行性	高	Diffy 支持开始节点、工具节点、LLM、代码、迭代、条件分支和聚合，能够实现单 BV 与批量 BV 的完整链路。
数据可得性	中高	B站公开视频通常可通过字幕插件获取；无字幕视频需增加 ASR，部分视频存在无字幕或接口限制。
格式稳定性	中	模型可能输出 think 标签、Markdown 代码块、重复 JSON 编码或缺字段，需要 Python 解析与兜底。
来源忠实度	中	模型容易压缩、重写或补充总结，必须设置原话保护规则并做逐条审核。
批量稳定性	中	单条运行已验证，批量迭代仍会遇到空结果、类型不匹配、HTTP 412 和聚合失败。
训练价值	高	经过单一话题、来源忠实度、风格强度和去重筛选后，可形成可追溯的 LoRA 数据集。

二、提效设计思路


整体设计采用“分层处理、每层只做一件事”的原则。字幕清洗、语义判断、风格分析、问题生成、格式化、去重和审核分别由不同节点负责，避免一个提示词承担过多任务，从而提高可解释性和可修复性。

1. 流程图

方案一：



方案二：



2. 提效原则

- 先规则后生成：先确定“什么能进训练集”，再让模型提取，避免产出后再大规模返工。

- 先原文后风格：assistant 回答优先保留原字幕，风格学习来自原话，而不是模型模仿。
- 代码处理确定性任务：JSON 解析、字符清洗、计数、数组合并和精确去重交给 Python。
- LLM 处理语义任务：话题边界、问题匹配、情绪强度、风格识别和语义重复交给大模型。
- 每个视频独立容错：单个 BV 失败不影响整个批次，保留 failed_video_count 和错误原因。
- 所有结果可追溯：每条样本保留 video_id、片段编号和 answer_source，便于回看原字幕。
- 评测前置：在真正训练前完成离线评测、Badcase 分类和准入筛选，减少污染训练。

三、Dify / PE 试跑效果

1. PE 设计

本周将工作流从“输入字幕后一次性生成问答”升级为可批量处理 BV 号的多节点 Agent。以下为主要节点设计及本周实际处理内容。

1.1 BV 输入与批量整理

开始节点接收 video_id、anchor_name、topic、part、subtitle_lang。单条模式直接传 BV 号；批量模式将一行一个 BV 转成数组后进入 Iteration。重点解决字符串与数组类型不一致、空行、重复 BV 和嵌套迭代不可用问题。

1.2 字幕提取

调用 Bilibili 字幕工具获取 video_title、video_author、current_part、subtitle_language 和 subtitles。已验证 BV16oNc6DEGd、BV188Jg6wENE 等视频；对“has no available subtitles”的视频记录为失败，不令其阻断整个批次。

1.3 数据清洗脚本

Python 删除 [00:01]、00:01、00:01:20、SRT 时间范围、单独序号、连续空格和异常换行；统一返回 clean_text 与 text_length。长字幕再按句子边界切块，设置 MAX_CHUNK_CHARS、OVERLAP_CHARS 和 MAX_TOTAL_CHARS，避免超出模型上下文。

1.4 字幕语义纠错

只允许修正明显错别字、断句和重复，不添加事实、不总结、不改变主播观点。该节点用于提高字幕可读性，但必须服从“最小清理”原则。

1.5 候选片段提取

从全部字幕块提取能够独立作为 assistant 回答的原始片段。优先级为：单一话题 → 问答逻辑 → 片段完整 → 字幕可靠 → 主播风格明显。输出 segment_id、content、topic、content_type、质量分和风险标记。

1.6 候选标准化与来源核验

逐条检查 candidate_content 是否来自 source_context。发现模型补写“世界观坍塌了”、压缩重组原字幕等情况时，标记 TRANSCRIPT_NOT_APPROVED、MODEL_REWRITE、INCOMPLETE 并剔除。

1.7 语义去重与必要合并

不仅比较字面重复，还比较核心观点、用户问题、案例和建议是否相同。对同一视频内的相近片段先去重，最终合并全部视频后再做全局去重。

1.8 主播语言风格分析

识别反问、短句、重复强调、类比、真实案例、调侃吐槽、转折和现实建议。输出 style_tags、anchor_style_score、spoken_naturalness 等字段，为训练样本筛选和后续评测提供依据。

1.9 情绪与表达强度分析

分析 tone、emotion_strength、情绪递进、直播互动感和幽默度。该节点不改写内容，只描述原片段的表达特征，避免将“风格标签”直接写进回答。

1.10 用户问题生成

根据原回答反推真实用户问题，要求包含用户背景、实际困惑、情绪和口语化表达。避免“普通人应该怎么选择工作？”这类过于标题化的问题，也避免为了匹配回答而新增不存在的前提。

1.11 训练样本组合

统一生成 messages：system 定义表达特征，user 放真实问题，assistant 放审核后的主播原话；metadata 保存 video_id、anchor_name、topic、style_tags、answer_source。

1.12 单条质量审核

从 source_fidelity、anchor_style、spoken_naturalness、question_quality、ai_smell、完整性和风险维度判断 passed。重点识别“首先/其次/然后/最后/综上所述/建议您”等 AI 整理腔。

1.13 单视频格式化

将每个 BV 的有效样本整理为 dataset，并统计 rejected_count、duplicate_count、empty_video_count、invalid_result_count。即便某个视频为空，也返回结构化结果而不是让节点报错。

1.14 批次合并与导出

Iteration 结束后汇总所有视频，生成 dataset_count、successful_video_count、failed_video_count、success、dataset_json 和 jsonl_text，可供 CSV、Excel、JSONL 或离线网站直接解析。

1.15 离线评测与报告系统

在原“主播 LoRA 训练集评测系统 V5”上增加 dataset_json 解析、原始字幕/音视频上传、逐条评测、总览统计、Badcase、评测报告和导出中心。用于训练前复核，也用于训练后对比盲测。

2. 当前进展（优化）

2.1 已完成

- 完成单 BV 字幕提取、清洗、语义分段、候选片段提取、问题生成和 messages 组装。
- 完成批量 BV 的数组整理、Iteration 逐视频处理和批次统计框架。
- 完成 think 标签、Markdown 代码块、重复 JSON 编码和异常数组的 Python 解析兼容。
- 完成候选片段标准化、原字幕忠实度检查、拒绝原因和风险标记输出。
- 完成同视频去重、批次级去重与必要合并逻辑。
- 完成主播语言风格、情绪与表达强度分析节点。
- 完成训练样本离线整理网页、评测系统和项目评测报告模块。
- 形成 JSON、JSONL、CSV、Excel 和表格展示所需的统一数据结构。

2.2 本周发现的关键问题

问题	表现	本周优化
批量运行不稳定	单条 BV 正常，批量时可能出现空结果、passed=false、聚合类型错误。	拆分节点职责；所有代码节点统一返回固定字段和空结果。
模型输出不规范	出现 <think>、```json、字符串套 JSON、字段缺失。	增加 remove_think_tags、remove_markdown_code、extract_json_object 和 parse_array。
模型改写主播原话	压缩、重组、补总结，导致来源不忠实。	把原话保护放在最高优先级，新增 source_context 对原话进行保护。
用户问题模板化	问题像标题或通用咨询，缺乏真实背景和情绪。	提示词强制“背景+困惑+情绪+口语”，并加入 question_type 限制。
AI 整理腔偏高	回答出现“首先、其次、最后”等书面结构。	增加 AI 腔词库和 ai_smell 指标，不合格样本直接拒绝。
重复样本偏多	不同片段表达同一核心观点，影响训练分布。	先视频内语义去重，再全局语义去重；保留最完整、/n
无字幕与接口限制	部分 BV 无字幕；主页批量抓取第8页出现 HTTP 412。	失败视频独立记录；后续补 ASR 与限速、缓存、分批/n
离线网站按钮无反应	页面脚本或数据结构不兼容，导出中心无法使用。	统一输入解析函数，增加错误提示、空状态和下载逻辑。

2.3 下一阶段计划

- 补齐无字幕视频的音频下载与 ASR 转写分支，实现“只输入 BV 号即可处理”。
- 把批量 Iteration 的输入、输出与聚合字段完全固定，建立 10/50/100 个 BV 的压力测试。
- 建立主播表达画像：高频句式、反问比例、句长、情绪强度、幽默度、案例类型与话题分布。
- 设定正式准入线：来源忠实度优先，一票否决模型补写；综合质量建议达到 90 分并保留人工抽检。

- 训练后进行盲测和 A/B 对比，验证模型是否学到主播表达，而不是只记住训练内容。
- 在离线网站中增加“原字幕—训练回答—模型回复”三栏对比和批量导出修复。

四、预估收益

以下收益为基于当前流程的阶段性的估算，实际结果取决于字幕质量、视频长度、模型调用速度、人工审核标准和最终准入比例。

收益维度	传统方式	自动化后	预期价值
素材处理	人工复制字幕、删时间戳	BV号自动提取与清洗	显著减少重复机械操作
片段筛选	人工通读全部字幕	模型候选提取 + 人工抽检	把审核集中在高价值候选上
问题生成	逐条手写或模板化生成	基于回答反推真实问题	提高问答匹配度和场景真实性
质量控制	依赖主观经验	固定评分、拒绝原因、风险标签	形成一致、可复盘的准入标准
批量交付	逐视频独立整理	Iteration + 汇总 + 多格式导出	支持数十至数百视频扩展
数据追溯	训练样本难回溯原文	保存 video_id 与 answer_source	便于纠错、审计和重新加工
训练效果	混入改写、重复、AI腔	来源忠实度与风格优先	降低模型学到错误表达的风险

1. 阶段性量化目标

- 单个 BV 可稳定完成全流程，并输出可直接训练的 JSONL。
- 批量任务中单个视频失败不影响其他视频，失败原因可定位。
- 候选样本必须经过来源忠实度审核，模型补写类样本准入率为 0。
- 重复数据在单视频和全局两个层级处理，保留最完整、最有风格的一条。
- 形成 300~500 条高质量样本后再启动第一轮 LoRA 训练，而不是只追求数量。
- 训练前后均使用同一评测体系，重点比较风格相似度、口语自然度、问题匹配和内容安全。



收益判断：本项目真正的收益不是“自动生成更多问答”，而是把主播数据整理从不可控的手工过程，变成有规则、有来源、有拒绝原因、有统计、有评测的工程化生产流程。

五、总结与思考

本周最大的进展，是将“做主播风格 LoRA 数据集”从一个模糊目标拆成了可执行的 Dify 工作流，并逐步建立了数据质量闭环。实践表明，主播风格训练最容易出现的误区是：为了让语言看起来更完整，让大模型主动总结、润色和仿写。这样虽然文本更顺，但会把原主播的口语节奏、真实停顿、反问方式和个人表达替换成通用 AI 文风，最终污染训练集。

因此，后续应继续坚持三个核心原则：第一，assistant 回答以原字幕为唯一事实来源；第二，模型只负责语义判断，不负责重新创作主播内容；第三，任何自动化结果都必须经过来源忠实度、问题匹

配、风格强度、AI 味和重复度审核。

从工程角度看，Dify 适合作为流程编排和实验平台，但批量生产仍需要更强的输入规范、固定输出协议、代码兜底、失败重试和离线评测。只有当“单条正确”升级为“批量稳定”，并通过训练后盲测证明模型确实学到了主播表达方式，这套系统才算真正完成。

最终结论

当前状态：方案可行，单条链路已基本跑通，质量规则与评测工具已形成；当前处于“批量稳定性优化 + 无字幕分支补齐 + 训练前正式准入”阶段。

训练建议：不要直接把所有生成结果用于训练。应优先选择来源忠实、单一话题、回答完整、用户问题真实、主播风格明显且无明显 AI 整理腔的样本。

下一里程碑：完成 300~500 条高质量样本，导出标准 JSONL，进行第一轮 LoRA 训练，并用未见过的问题做盲测与 A/B 对比。



附录：最终训练数据结构示例

```
{
  "messages": [
    {"role": "system", "content": "你是一位表达直接、口语化、有强烈个人观点的主播。"},
    {"role": "user", "content": "我现在有份稳定工作，但总觉得没前景，又不敢辞职，怎么办？"},
    {"role": "assistant", "content": "这里放经过原字幕核验的主播原话片段。"}
  ],
  "metadata": {
    "video_id": "BVxxxx",
    "anchor_name": "目标主播",
    "topic": "职业选择",
    "style_tags": ["反问", "口语化", "现实建议"],
    "answer_source": "transcript"
  }
}
```





网站数据处理流程

原始视频



ASR语音转写



文本清洗



结构化分段

数据工厂

视频文本数据处理平台

首页

流水线

文件审查

模板编辑器

历史记录

登

✓

输入视频

✓

提取音频

✓

ASR识别

✓

文本清洗

5

结构化分段

6

维度分析

7

标签构建

8

数据标注

9

质量审核

10

导出数据

视频 8 / 8

https://www.bilibili.com/video/BV1EAj96ZEfn/?spm_id_from=333....

https://www.bl... (1)

https://www.bl... (2)

https://www.bl... (3)

https://www.bl... (4)

https://www.bl... (5)

https://www.bl... (6)

https://www.bl... (7)

https://www.bl... (8)

结构化分段

按语义自然分段；标点少时按长度兜底，每段约 300 字，不限制段数

分段配置

最小长度

50

字

目标长度

300

字

会尽量接近该长度；标点少时按长度硬切，段数自然增加。

清洗后文本

16391 字

干啥可能都有点不太行明白对就是大概昨天前天因为人是找我一趟他们因为我们是自己的指数领导吗会给我们反馈就是可能要给人生反馈问题人是要找我因为他第一句话找我的第一句话就说你在楼下待得怎么样我说还好他就下一个跟我说老板有点纠结我就知道不太对了就是老板就跟我老板要再纠结我在想到底纠结我确实留吗他是意思就是可能我在楼下领导反馈的问题我可能太有自己的想法就是让我干我不这么干可能有自己的想法去做另外一种方式去干可能反馈的问题比较多我可以举个例子比如说一个状态什么有一次我在楼下突油期突油期那会儿刚上班没多久我确实不太会开可能一直理由但是我想等两分钟有个人高我用啥工具大概我只要他们开了正好被我们领导的就是这。

分段结果 65 段

第 1 段 编辑主题: 其他

301 字

干啥可能都有点不太行明白对就是大概昨天前天因为人是找我一趟他们因为我们是自己的指数领导吗会给我们反馈就是可能要给人生反馈问题人是要找我因为他第一句话找我的第一句话就说你在楼下待得怎么样我说还好他就下一个跟我说老板有点纠结我就知道不太对了就是老板就跟我老板要再纠结我在想到底纠结我确实留吗他是意思就是可能我在楼下领导反馈的问题我可能太有自己的想法就是让我干我不这么干可能有自己的想法去做另外一种方式去干可能反馈的问题比较多我可以举个例子比如说一个状态什么有一次我在楼下突油期突油期那会儿刚上班没多久我确实不太会开可能一直理由但是我想等两分钟有个人高我用啥工具大概我只要他们开了正好被我们领导的就是这。

全部视频分段完成



已完成 8 个视频的结构化分段

返回

重新分段

下一步: 维度分析

维度分析



标签

数据工厂

视频文本数据处理平台

首页

流水线

文件审查

模板编辑器

历史记录

登录

职业选择 (主题)

职场成长 (主题)

口语化 (风格)

观点阐述 (表达)

对比论证 (逻辑)

年轻人 (受众)

职业选择 (主题)

对比论证 (逻辑)

年轻人 (受众)

职场成长 (主题)

口语化 (风格)

观点阐述 (表达)

职业规划 (主题)

职业转型 (主题)

入职 (主题)

求职 (主题)

融入团队 (主题)

执行力 (主题)

团队合作 (主题)

办公室关系 (主题)

直属领导 (主题)

工作汇报 (主题)

薪资 (主题)

晋升 (主题)

加班 (主题)

焦虑 (主题)

裸辞 (主题)

裁员 (主题)

学习 (主题)

应届生 (主题)

标签体系已建立

已添加 27 个标签，可用于后续数据标注

批量生成全部标签

应用当前标签到全部视频

全部视频标签构建完成

已完成 8 个视频的标签体系构建

返回

下一个视频

数据集

数据工厂

视频文本数据处理平台

首页

流水线

文件审查

模板编辑器

历史记录

登录

标签构建

数据标注

质量审核

导出数据

视频 8 / 8

https://www.bilibili.com/video/BV1EAj96ZEfn/?spm_id_from=333....

https://www.bi... (1)

https://www.bi... (2)

https://www.bi... (3)

https://www.bi... (4)

https://www.bi... (5)

https://www.bi... (6)

https://www.bi... (7)

https://www.bi... (8)

数据标注

A 必须直接回答 Q，像真实职场主播和人交流；每条重复率低于 60%

生成设置

生成数量

10

1-50 条，Q 10-100 字，A 100-300 字，A 必须回答 Q

手动新增 QA 样本

选择分段来源

请选择

Q: 标签范围内提问

围绕标签随便问一个真实职场问题，10-100 字。

A: 主播口播回答

像真实职场主播面对镜头回答这个 Q，100-300 字，不能答非所问。

选择标签

AI

人工智能

专业严谨

职业选择

对比论证

年轻人

职场成长

口语化

观点阐述

职业规划

职业转型

入职

求职

融入团队

执行力

团队合作

办公室关系

直属领导

工作汇报

薪资

晋升

加班

焦虑

裸辞

裁员

学习

应届生

+ 添加样本

已标注样本

10 条

Q:

我怕自己想偏了，我该怎么把执行力从想法变成行动?

A:

先别急，我给你拆一下，别把这件事想得太玄，它最后一定要回到你的日常行动里。如果你准备跳槽，先问继续三个月能得到什么，离开又会损失什么。用专业严谨的语气说，就是先承认现实压力，再给出可以执行的顺序。先选一个最小动作去做，比如沟通一次、补一个技能点、拿出一个可展示的成果。先做低成本验证，再做大决定，这会稳很多。

AI

人工智能

专业严谨

职业选择

对比论证

Q:

如果是你会怎么看，我该怎么把未来从想法变成行动?

A:

这个问题我先接一下，这个问题不能只给一句口号式答案。如果按“概念-原理-应用-案例”来看，先别急着问结果，先看你现在最缺的是信息、能力，还是资源。如果你对未来没方向，就先列出不想要的工作状态，这也是边界。表达上保持语速较慢，条理清晰，但重点不是讲漂亮话，是把“薪资”落成一个今天能做的小动作。底线清楚，行动具体，焦虑就不会一直牵着你了。

AI

人工智能

专业严谨

职业选择

对比论证

数据标注完成

已生成 10 条低重复 QA 训练样本

质量审核

数据工厂
视频文本数据处理平台

首页

流水线

文件审查

模板编辑器

历史记录

✓
输入视频

✓
提取音频

✓
ASR识别

✓
文本清洗

✓
结构化分段

✓
维度分析

✓
标签构建

✓
数据标注

9
质量审核

10
修正复核

11
导出数据

视频 1 / 2

https://www.bilibili.com/video/BV17ZKU6JEME/?spm_id_from=33...

https://www.bl... (1)

https://www.bl... (2)

质量审核

数据层、风格层、格式层三重检查；审核 0.1，保持稳定判断

数据层检查

✓ 重复数据 0%

✗ 错误数据 80%

⚠ 主题匹配 40%

风格层检查

⚠ 风格匹配 20%

✓ 风格一致 一致

格式层检查

✓ JSON格式 100%

平均Query长度 21 字

平均Answer长度 152 字

存在待修正项

共 10 条样本，2 条通过，8 条失败

样本详情检查

#1 如果竞争力让我很内耗，今天能先做什么？ ...

需修正

- A 没有直接回应 Q 的核心主题

- A 模板痕迹明显，不像自然直播回答

#2 想做长期规划的时候，怎么判断自己是在成长还是消耗？ ...

需修正

- A 没有直接回应 Q 的核心主题

#3 想换方向又怕选错，怎么判断更稳？ ...

需修正

- A 没有直接回应 Q 的核心主题

返回

去修正当前视频

下一个视频

重新开始

导出数据

数据工厂

视频文本数据处理平台

首页

流水线

文件审查

模板编辑器

历史记录

数据工厂

从视频到训练数据的完整流水线

✓

输入视频

✓

提取音频

✓

ASR识别

✓

文本清洗

✓

结构化分段

✓

维度分析

✓

标签构建

✓

数据标注

✓

质量审核

✓

修正复核

11

导出数据

视频 2 / 2

https://www.bilibili.com/video/BV1DLN6IE84/?spm_id_from=333...

https://www.bi... (1)

https://www.bi... (2)

导出数据

生成训练数据集，支持多种格式和自定义模板

模板配置

选择预设模板

Alpaca标准格式

完整字段格式

仅Query-Answer

自定义字段

videoUrl

string

×

query

string

×

answer

string

×

instruction

string

×

添加字段

导入Excel模板

从Excel导入字段

数据概览

20

样本总数

20

通过审核

2

视频数量

6

输出字段

train.jsonl

Alpaca格式

train.xlsx

Excel格式

train.csv

CSV格式

全部导出

所有格式

重新开始

文件审核



文件审查


检查每条数据的重复率和疑似错别字，修复后下载文件。



拖拽文件到这里

支持 txt、csv、jsonl、xlsx；每行或每条记录作为一条数据。

📁 导入文件



第一版

代码块

```
1  # Role
2  你是一名资深AI数据运营工程师和LoRA微调专家，擅长将原始视频数据转化为高质量的模型微调数据集。
3
4  # Task
5  根据用户提供的哔哩哔哩BV号，自动完成以下全流程数据处理：
6  1. 获取视频元数据（标题、简介、UP主、播放量、弹幕、评论等）
7  2. 提取视频关键帧作为视觉素材
8  3. 将数据结构化整理为适用于LoRA微调的测试集与验证集
9  4. 输出JSONL文件和XLSX工作表
10
11 # Input
12 - 输入格式：单个或多个哔哩哔哩BV号
13 - 输入示例：BV1xx411c7mN, BV1xx411c7mO, BV1xx411c7mP
14 - 输入数量：支持1-100个BV号批量处理
15
16 # Output
17 ## 输出文件格式（必须同时输出两种格式）
18
19 ### 1. JSONL文件（每行一条数据，UTF-8编码）
20 文件名格式：{当前日期}_{数据集类型}.jsonl
21
```

```
22 JSONL字段结构:
23 ```json
24 {
25     "video_id": "BV1xx411c7mN",
26     "video_url": "https://www.bilibili.com/video/BV1xx411c7mN",
27     "title": "视频标题",
28     "description": "视频简介",
29     "uploader": "UP主名称",
30     "uploader_url": "UP主主页URL",
31     "view_count": 10000,
32     "like_count": 500,
33     "comment_count": 100,
34     "danmaku_count": 200,
35     "duration": 3600,
36     "tags": ["标签1", "标签2"],
37     "category": "视频分类",
38     "publish_time": "2026-07-14 12:00:00",
39     "keyframes": [
40         {"timestamp": 0, "image_url": "https://example.com/frame_0.jpg"},
41         {"timestamp": 10, "image_url": "https://example.com/frame_10.jpg"}
42     ],
43     "danmaku_sample": ["弹幕1", "弹幕2"],
44     "comment_sample": ["评论1", "评论2"],
45     "data_split": "train"
46 }
47 ```
```

2. XLSX文件 (包含5个工作表)

文件名格式: {当前日期}_lora_dataset.xlsx

- Sheet1: video_metadata (视频元数据)
- Sheet2: keyframes (关键帧信息)
- Sheet3: danmaku (弹幕数据)
- Sheet4: comments (评论数据)
- Sheet5: dataset_split (数据集划分)

Rules

1. **数据划分**：训练集80%，验证集20%，按发布时间分层抽样
2. **关键帧提取**：每10秒1帧，最多50帧/视频，优先清晰主体帧
3. **弹幕采样**：最多100条/视频，按时间均匀分布
4. **评论采样**：最多50条/视频，优先高点赞评论
5. **数据清洗**：去重、过滤无意义内容、统一时间格式

Quality Check

- [] 所有BV号均已处理
- [] JSONL格式正确 (UTF-8, 每行一个JSON对象)
- [] XLSX包含所有5个工作表
- [] 数据划分比例正确 (80%/20%)

- 69 - [] 每个视频至少5个关键帧、10条弹幕、5条评论
- 70 - [] JSONL和XLSX数据完全一致

最终版

代码块

```
1
2  ### 编辑器操作规则
3  1. **添加字段**：从可用字段列表拖拽到配置面板，或点击添加按钮
4  2. **删除字段**：点击字段旁边的删除按钮
5  3. **编辑字段属性**：在属性配置面板修改字段名称、类型、数据源等
6  4. **调整字段顺序**：拖拽字段调整输出顺序
7  5. **设置条件**：为每个字段添加条件规则，控制是否输出
8  6. **实时预览**：修改配置后自动更新预览面板
9  7. **保存模板**：将当前配置保存为JSON模板文件
10 8. **加载模板**：从文件导入已保存的模板配置
11
12 ## 模板文件格式
13 ### JSON模板示例
14 ```json
15 {
16     "version": "1.0",
17     "description": "自定义输出格式模板",
18     "editor_config": {
19         "layout": "horizontal",
20         "show_preview": true,
21         "auto_save": false
22     },
23     "output_fields": [
24         {
25             "name": "video_id",
26             "type": "string",
27             "required": true,
28             "source": "bv_id",
29             "transform": null,
30             "default": null,
31             "condition": null,
32             "order": 1
33         },
34         {
35             "name": "transcript",
36             "type": "string",
37             "required": true,
38             "source": "asr_text",
39             "transform": null,
```

```

40     "default": null,
41     "condition": {
42         "field": "language_style.tone",
43         "operator": "equals",
44         "value": "正式",
45         "action": "include"
46     },
47     "order": 2
48 },
49 {
50     "name": "tags",
51     "type": "array",
52     "required": false,
53     "source": "keywords",
54     "transform": "extract_words",
55     "default": [],
56     "condition": {
57         "field": "keywords.length",
58         "operator": "greater_than",
59         "value": 0,
60         "action": "include"
61     },
62     "order": 3
63 }
64 ],
65 "format_rules": {
66     "jsonl": {"enabled": true, "indent": false},
67     "xlsx": {"enabled": true, "sheets": ["main_data"]},
68     "csv": {"enabled": true, "delimiter": ","},
69     "parquet": {"enabled": false}
70 }
71 }
72 ```
73
74 ### XLSX模板示例
75 - 包含表头的Excel文件，支持多行列配置
76 - 第一行：字段名
77 - 第二行：数据类型
78 - 第三行：数据源
79 - 第四行：是否必填
80 - 第五行：条件规则（JSON格式）
81
82 # Output
83 ## 默认输出格式（未导入模板时使用）
84
85 ### 1. JSONL文件格式（每行一个JSON对象）
86 ```jsonl

```

```

87  {
88      "bv_id": "BV1xx411c7mZ",
89      "asr_text": "完整的语音转文字内容，保留原始口语特征",
90      "text_segments": [
91          {"segment_id": "s1", "content": "第一段语义完整的文本内容，通常包含一个完整的话题或观点", "topic": "段落主题"},
92          {"segment_id": "s2", "content": "第二段语义完整的文本内容，通常包含一个完整的话题或观点", "topic": "段落主题"}
93      ],
94      "language_style": {
95          "tone": "正式/口语化/幽默/严肃/轻松",
96          "vocabulary": "专业术语丰富/日常用语/网络流行语",
97          "sentence_structure": "长句为主/短句为主/复合句多/简单句多",
98          "rhythm": "语速快/语速慢/停顿频繁/流畅连贯",
99          "emotion": "中性/热情/冷静/激动/沉稳"
100     },
101     "expression_style": {
102         "narration": "平铺直叙/故事性强/悬念设置/层层递进",
103         "emphasis": "重复强调/对比突出/数据支撑/案例说明",
104         "interaction": "自问自答/引导思考/直接陈述/互动频繁"
105     },
106     "logic_style": {
107         "structure": "总分总/分总/总分/线性叙述/发散思维",
108         "reasoning": "归纳推理/演绎推理/类比推理/经验总结",
109         "argumentation": "事实论证/逻辑论证/情感论证/权威论证"
110     },
111     "keywords": [
112         {"word": "关键词1", "weight": 0.95, "category": "专业术语"},
113         {"word": "关键词2", "weight": 0.88, "category": "核心概念"},
114         {"word": "关键词3", "weight": 0.75, "category": "高频表达"}
115     ],
116     "style_signature": [0.85, 0.72, 0.91, 0.68, 0.79, 0.83, 0.76, 0.88, 0.71, 0.84],
117     "created_at": "2026-07-14T10:30:00Z"
118 }
119 ...
120
121 ### 2. XLSX文件（包含3个工作表）
122 - **Sheet1: video_data** - 视频主数据表
123 - **Sheet2: text_segments** - 文本分段表
124 - **Sheet3: style_similarity** - 风格相似度矩阵
125
126 ### 3. CSV文件格式
127 - 文件名：`loras_training_data_{yyyyMMdd}_{HHmmss}.csv`
128 - 结构：与XLSX的video_data工作表相同
129
130 ### 4. Parquet文件格式

```

```

131 - 文件名: `lora_training_data_{yyyyMMdd}_{HHmmss}.parquet`
132 - 结构: 与JSONL字段相同
133
134 ## 模板自定义输出格式
135 - 根据模板编辑器配置调整输出字段名称、顺序、类型
136 - 根据条件规则动态决定是否输出某些字段
137 - 支持字段映射、转换和默认值设置
138 - 支持启用/禁用特定输出格式
139 - 支持自定义XLSX工作表结构
140
141 # Rules
142
143 ## 模板编辑器规则
144 1. **可视化编辑**：提供拖拽式界面，支持所见即所得编辑
145 2. **实时预览**：修改配置后即时更新预览结果
146 3. **字段管理**：支持添加、删除、编辑、排序字段
147 4. **属性配置**：支持配置字段名称、类型、数据源、转换函数、默认值、条件规则
148 5. **模板保存**：支持将配置保存为JSON或XLSX格式模板文件
149 6. **模板加载**：支持从文件导入模板配置
150 7. **导入/导出**：支持模板的导入和导出
151
152 ## 条件输出规则
153 ### 条件表达式语法
154 ```json
155 {
156     "field": "数据源字段路径",
157     "operator": "比较运算符",
158     "value": "比较值",
159     "action": "include/exclude"
160 }
161 ```
162
163 ### 支持的运算符
164 | 运算符 | 说明 | 示例 |
165 |-----|-----|-----|
166 | equals | 等于 | {"field": "tone", "operator": "equals", "value": "正式"} |
167 | not_equals | 不等于 | {"field": "tone", "operator": "not_equals", "value": "口语化"} |
168 | greater_than | 大于 | {"field": "keywords.length", "operator": "greater_than", "value": 5} |
169 | less_than | 小于 | {"field": "keywords.length", "operator": "less_than", "value": 10} |
170 | greater_than_or_equal | 大于等于 | {"field": "weight", "operator": "greater_than_or_equal", "value": 0.8} |
171 | less_than_or_equal | 小于等于 | {"field": "weight", "operator": "less_than_or_equal", "value": 0.5} |
172 | contains | 包含 | {"field": "tags", "operator": "contains", "value": "AI"} |

```

```
173 | not_contains | 不包含 | {"field": "tags", "operator": "not_contains",
174 | is_empty | 为空 | {"field": "keywords", "operator": "is_empty", "value":
175 | is_not_empty | 不为空 | {"field": "keywords", "operator": "is_not_empty",
176 | "value": true} |
177 ### 条件组合规则
178 1. **AND组合**：多个条件同时满足才触发
179 2. **OR组合**：满足任一条件即触发
180 3. **嵌套条件**：支持条件嵌套
181 4. **优先级**：支持使用括号改变运算优先级
182
183 ### 条件动作规则
184 1. **include**：条件满足时输出该字段
185 2. **exclude**：条件满足时不输出该字段
186 3. **set_default**：条件满足时使用默认值
187 4. **transform**：条件满足时应用转换函数
188
189 ### 字段级条件规则
190 1. 每个字段可以设置独立的条件规则
191 2. 条件规则基于该字段的数据源或其他字段的值
192 3. 支持跨字段条件判断
193 4. 条件不满足时的处理：
194     - required字段：使用默认值或标记为缺失
195     - optional字段：不输出该字段
196
197 ## 模板导入规则
198 1. 支持JSON和XLSX两种模板格式
199 2. 模板文件必须包含输出字段定义和数据源映射
200 3. 模板中的字段名可以与默认字段名不同
201 4. 支持自定义字段（不在默认字段列表中的字段）
202 5. 自定义字段可以设置默认值或通过表达式计算
203
204 ## 字段映射规则
205 1. 使用`field_mapping`或模板中的`source`字段指定数据源
206 2. 支持的数据源字段：bv_id, asr_text, text_segments, language_style,
207    expression_style, logic_style, keywords, style_signature, created_at
208 3. 支持字段转换：
209     - extract_words：从keywords数组中提取word字段
210     - json_stringify：将对象转换为JSON字符串
211     - join：将数组元素用指定分隔符连接
212     - uppercase：转换为大写
213     - lowercase：转换为小写
214
215 ## 模板验证规则
216 1. 验证模板文件格式是否正确
```

216 2. 验证所有required字段都有对应的数据源
217 3. 验证数据源字段是否存在
218 4. 验证字段类型是否匹配
219 5. 验证条件表达式语法是否正确
220 6. 验证格式规则是否有效
221
222 ## 批量处理规则
223 1. 支持同时处理1-100个BV号
224 2. 按输入顺序处理, 保持输出顺序一致
225 3. 单个视频处理失败不影响其他视频
226 4. 生成处理报告, 包含成功/失败统计
227
228 ## ASR文本提取规则
229 1. 必须获取完整的语音转文字内容, 不得遗漏任何语音片段
230 2. 保留原始口语特征, 包括语气词、口头禅、重复表达
231 3. 去除明显的噪音和无意义的停顿
232 4. 标点符号使用规范, 符合中文表达习惯
233
234 ## 文本分段规则
235 1. 按语义自然分段, 每段包含一个完整的话题或观点
236 2. 每段长度控制在50-200字之间
237 3. 确保段落之间逻辑连贯, 语义完整
238 4. 为每段添加简短的主题描述 (不超过10字)
239
240 ## 语言风格分析规则
241 1. 基于ASR文本上下文进行分析, 不得主观臆断
242 2. 分析维度必须覆盖语气、词汇、句式、节奏、情感五个方面
243 3. 每个维度给出具体的特征描述, 禁止模糊表达
244
245 ## 表达风格分析规则
246 1. 分析叙述方式: 平铺直叙/故事性强/悬念设置/层层递进
247 2. 分析强调方式: 重复强调/对比突出/数据支撑/案例说明
248 3. 分析互动方式: 自问自答/引导思考/直接陈述/互动频繁
249
250 ## 逻辑风格分析规则
251 1. 分析逻辑结构: 总分总/分总/总分/线性叙述/发散思维
252 2. 分析推理方式: 归纳推理/演绎推理/类比推理/经验总结
253 3. 分析论证方式: 事实论证/逻辑论证/情感论证/权威论证
254
255 ## 关键词提取规则
256 1. 提取5-10个最具代表性的关键词
257 2. 关键词必须与视频主题高度相关
258 3. 关键词应具有区分度, 避免通用词汇
259 4. 为每个关键词计算权重值 (0-1之间), 权重基于出现频率和重要性
260 5. 权重计算规则:
261 - 出现频率越高, 权重越高
262 - 在核心观点中出现, 权重增加0.2

```
263     - 专业术语权重基础值0.7，日常词汇权重基础值0.4
264 6. 对关键词进行分类：专业术语、核心概念、高频表达
265
266 ## 风格相似度计算规则
267 1. 将每个视频的风格特征量化为10维特征向量 (style_signature)
268 2. 特征向量维度定义：[语气，词汇，句式，节奏，情感，叙述，强调，互动，逻辑结构，推理方式]
269 3. 每个维度归一化为0-1之间的数值
270 4. 使用余弦相似度计算两个视频之间的风格相似度
271 5. 相似度取值范围：0-1，1表示完全相同，0表示完全不同
272 6. 生成N×N的相似度矩阵（N为视频数量）
273
274 ## 格式转换规则
275 1. 根据模板配置决定输出格式类型
276 2. 所有启用的格式数据内容必须完全一致
277 3. CSV使用UTF-8 with BOM编码，确保中文正常显示
278 4. Parquet使用Snappy压缩，优化存储和读取性能
279
280 # Constraints
281 1. **禁止**提取标题、简介、UP主、播放量、弹幕、评论等视频元数据
282 2. **禁止**添加任何主观评价或个人观点
283 3. **必须**严格按照模板配置的格式输出
284 4. **必须**确保数据的准确性和完整性
285 5. **必须**处理空值和异常情况，确保输出文件格式正确
286 6. **必须**验证模板文件的有效性，无效模板使用默认格式
287 7. **必须**正确执行条件输出规则，确保字段按条件输出或排除
288 8. 单个BV号处理时间不超过60秒
289 9. 批量处理时，总处理时间不超过视频数量×60秒
290
291 # Examples
292
293 **输入示例（带条件输出）**：
294 ```json
295 {
296     "bv_list": ["BV1xx411c7mZ", "BV2yy422d8nA"],
297     "template": {
298         "type": "json",
299         "file_path": "/templates/custom_format.json"
300     },
301     "conditions": [
302         {"field": "language_style.tone", "operator": "equals", "value": "正式",
303         "action": "include"},
304         {"field": "keywords.length", "operator": "greater_than", "value": 5,
305         "action": "exclude"},
306     ]
307 }
```



```

307         {"field": "emotion", "operator": "equals", "value": "热情"},
308         {"field": "rhythm", "operator": "equals", "value": "语速快"}
309     ],
310     "action": "include"
311 }
312 ]
313 }
314 ```
315
316 **带条件的模板文件示例**：
317 ```json
318 {
319     "version": "1.0",
320     "description": "带条件输出的模板",
321     "output_fields": [
322         {"name": "video_id", "type": "string", "required": true, "source":
323         "bv_id", "condition": null},
324         {"name": "transcript", "type": "string", "required": true, "source":
325         "asr_text", "condition": null},
326         {
327             "name": "tone",
328             "type": "string",
329             "required": false,
330             "source": "language_style.tone",
331             "condition": {"field": "language_style.tone", "operator": "equals",
332             "value": "正式", "action": "include"}
333         },
334         {
335             "name": "keywords",
336             "type": "array",
337             "required": false,
338             "source": "keywords",
339             "transform": "extract_words",
340             "condition": {"field": "keywords.length", "operator": "greater_than",
341             "value": 0, "action": "include"}
342         },
343         {
344             "name": "emotion",
345             "type": "string",
346             "required": false,
347             "source": "language_style.emotion",
348             "condition": {
349                 "operator": "AND",
350                 "conditions": [
351                     {"field": "language_style.emotion", "operator": "equals", "value":
352                     "热情"},

```

```


348         {"field": "language_style.rhythm", "operator": "equals", "value": "语
    速快"}
349     ],
350     "action": "include"
351 }
352 }
353 ],
354     "format_rules": {"jsonl": {"enabled": true}, "xlsx": {"enabled": true}}
355 }
356 ```
357
358 **条件输出示例**：
359 ```jsonl
360 {"video_id":"BV1xx411c7mZ","transcript":"大家好，欢迎来到今天的AI技术分
    享...","tone":"正式","keywords":["LoRA","微调","参数高效"]}
361 {"video_id":"BV2yy422d8nA","transcript":"嘿各位小伙伴，今天给大家带来一期超实用的教
    程...","emotion":"热情"}
362 ```
363
364 # Output Format
365 1. JSONL文件：`lora_training_data_{yyyyMMdd}_{HHmmss}.jsonl`
366 2. XLSX文件：`lora_training_data_{yyyyMMdd}_{HHmmss}.xlsx`
367 3. CSV文件：`lora_training_data_{yyyyMMdd}_{HHmmss}.csv`（根据模板启用）
368 4. Parquet文件：`lora_training_data_{yyyyMMdd}_{HHmmss}.parquet`（根据模板启用）
369 5. 处理报告：`processing_report_{yyyyMMdd}_{HHmmss}.txt`
370 6. 模板验证报告：`template_validation_report_{yyyyMMdd}_{HHmmss}.txt`（如导入模板）
371 7. 条件执行报告：`condition_execution_report_{yyyyMMdd}_{HHmmss}.txt`（如设置条件）
372
373 # Quality Check
374 1. [ ] 模板验证通过（如导入模板）
375 2. [ ] 条件表达式语法正确（如设置条件）
376 3. [ ] 所有输入BV号均已处理
377 4. [ ] 文本分段合理性：每段50-200字，语义完整
378 5. [ ] 关键词权重准确性：权重值在0-1之间，计算逻辑正确
379 6. [ ] 风格相似度正确性：对角线为1，矩阵对称
380 7. [ ] 格式一致性：所有启用格式的数据完全一致
381 8. [ ] 字段映射正确：模板字段与数据源正确映射
382 9. [ ] 条件输出正确：字段按条件正确输出或排除
383 10. [ ] 异常处理：失败视频已记录到处理报告
384 11. [ ] 文件命名规范：所有文件包含日期时间戳
385 12. [ ] 处理报告完整：包含成功/失败统计和错误详情

```

问题

用户6618143382

大约两个半小时的视频，只能取出189个字吗？是哪里出了问题呢？



AI数据运营Prompt专家

思考过程

```
src/components/pipeline/StepExtract.tsx
src/components/pipeline/StepAut.tsx
```

Thought

我发现有问题！当前系统使用的是模拟数据，而不是真实的ASR识别。模拟文本的长度非常短（只有几十到一百多字），这就是为什么两个半小时的视频只能取出189个字。

让我先增加模拟数据的长度，使其更接近真实视频的文本量：

StepExtract.tsx


src/components/pipeline...

+14 -7

查看差异

Thought

我上传的视频网址1小时44分钟8秒的视频，提取出来的是3并且绿框数字乱动



AI数据运营Prompt专家

思考过程

我来修复这两个问题：

1. 时长问题：当前硬编码为3分钟，需要支持自定义时长

2. 数字乱动：播放进度更新太快，需要平滑显示

```
src/components/pipeline/StepExtract.tsx
```

Thought

Codex

我需要在用户输入网站中提取出的真实视频及真实音频，还有通...



真的一点问题都没有吗

已处理 5m 24s

不是，肯定还有问题。你截图里的“全通过”其实不可信，因为原来的质量审核太宽松了：只要 Q/A 不为空、长度够、qualityScore 是 92，就基本会通过。

我已经把质量审核改严了，现在会逐条检查：

- Q 是否和前面过于相似
- A 是否和前面过于相似
- Q/A 是否真的对齐
- A 是否没有直接回应 Q 的核心主题

要求后续变更

- Q 开头是否模板化重复，比如同一批里很多条都用“我给自己帮了...”

转我审批

5.5 中

IDE 上下文

流水线中的质量审核后面加一个步骤，可以结合之前的内容进行修正，可以选择批量修正，可以选择二次审核

已处理 13m 11s

已加好。

现在流水线变成：

数据标注 -> 质量审核 -> 修正复核 -> 导出数据

新增的“修正复核”支持：

- 修正当前视频的问题 QA
- 批量修正全部视频
- 批量修正并二次审核
- 单独对当前视频做二次审核

修正时会自动检查、分段、原 Q/A、审核失败原因，重点处理：答非所问、Q/A 重复、长度不符合